FACULTADE DE MATEMÁTICAS

Trabajo Fin de Grado

Introducción a los modelos de series de tiempo

Iván Lado Canosa

Curso Académico 2024/2025

UNIVERSIDADE DE SANTIAGO DE COMPOSTELA

GRAO DE MATEMÁTICAS

Trabajo Fin de Grado

Introducción a los modelos de series de tiempo

Iván Lado Canosa

Julio, 2025

UNIVERSIDADE DE SANTIAGO DE COMPOSTELA

Trabajo propuesto

Área de Conocimiento: Estadística e Investigación Operativa, Dpto. de Estadística, Análisis Matemática y Optimización.
Título: Introducción a los modelos de series de tiempo.
Breve descrición del contenido
En este Trabajo de Fin de Grado se presentará una introducción a los modelos de series de tiempo, en la que se revisarán los conceptos de estacionariedad y estacionalidad. Se abordará el problema del ajuste de modelos de tipo autorregresivo, de medias móviles e integrados (AR, MA, ARMA, ARIMA) y la construcción de predicciones. Se presentará la metodología en detalle y se ilustrará con datos reales y/o simulados, así como posibles extensiones de los modelos anteriores.

Índice

Resumen IX

1. Motivación y ejemplos de series de tiempo 1

1.1. Objetivos de este Trabajo Fin de Grado 3

1.2. Estructura del trabajo 4

2. Modelos clásicos 5

2.1. Estimación de μ, $\gamma(\cdot)$ y $\rho(\cdot)$. 9

2.1.1. Estimación de μ. 9

2.1.2. Estimación de $\gamma(\cdot)$ y $\rho(\cdot)$. 10

2.1.3. Estimación de $\alpha(\cdot)$. 10

2.2. Convergencia de series de variables aleatorias 10

2.3. Procesos estacionarios 12

2.3.1. Procesos de medias móviles (MA) 12

2.3.2. Procesos autorregresivos (AR) 13

2.3.3. Procesos autorregresivos de medias móviles (ARMA) 14

2.4. Procesos no estacionarios 17

2.4.1. Procesos autorregresivos integrados de medias móviles (ARIMA) 17

2.4.2. Procesos ARIMA estacionales (SARIMA) 18

2.5. Predicción 18

2.5.1. Mejor predictor lineal 19
2.5.2. Predicción mediante esperanzas condicionadas 19
2.5.3. Varianza de las predicciones 22
2.5.4. Consideraciones sobre la predicción en la práctica 23
2.6. Estimación de procesos ARMA 24
2.6.1. Estimación de Yule-Walker para procesos autorregresivos 25
2.6.2. Estimación por máxima verosimilitud 26
2.7. Selección de modelos mediante el criterio de información de Akaike 31
2.8. Metodología para el análisis de series de tiempo 31
2.8.1. Etapa 1: Identificación de modelos compatibles con la serie de tiempo . . 32
2.8.2. Etapa 2: Estimación de los modelos candidatos 34
2.8.3. Etapa 3: Diagnosis del modelo 34
2.8.4. Constraste de raíz unitaria Dickey-Fuller 35
2.8.5. Incorrelación de los residuos 35
2.8.6. Media de los residuos 36

3. Estudio de simulación 37

3.1. Estimación 37
3.1.1. Simulación de procesos AR 38
3.1.2. Simulación de procesos MA 41
3.1.3. Simulación de procesos ARMA 41
3.1.4. Simulación de procesos SARIMA 42
3.2. Predicción 43
3.2.1. Predictores usados 44
3.2.2. Discusión de los resultados 47

4. Ilustración con datos reales 51

4.1. Análisis de la serie de tiempo del IBEX 35 51

4.1.1. Etapa 1: Identificación de modelos compatibles con la serie 51

4.1.2. Etapa 2: Estimación de los modelos y selección de un modelo 53

4.1.3. Etapa 3: Diagnosis del modelo seleccionado 53

4.1.4. Predicciones 54

4.2. Análisis de la serie de tiempo de consumo mensual de electricidad 55

4.2.1. Etapa 1: Identificación de modelos compatibles con la serie 55

4.2.2. Etapa 2: Estimación de los modelos candidatos y selección de un modelo . 57

4.2.3. Etapa 3: Diagnosis del modelo seleccionado 57

4.2.4. Predicciones 58

I. Resultados de teoría de la probabilidad usados 61

Bibliografía 63

Resumen

El estudio de series de tiempo constituye una herramienta fundamental en el análisis de datos que evolucionan a lo largo del tiempo, permitiendo modelar y predecir fenómenos en campos como la economía, la meteorología, la ingeniería o las ciencias sociales.

Este Trabajo Fin de Grado aborda el análisis de series de tiempo desde una perspectiva estadística clásica, considerando que las series observadas son realizaciones de procesos estocásticos. Se presentan en detalle los modelos autorregresivos (AR), de medias móviles (MA), mixtos (ARMA), integrados (ARIMA) y estacionales (SARIMA), explicando su formulación matemática, los métodos de estimación de sus parámetros y las técnicas de predicción asociadas. Asimismo, se propone una metodología para el análisis de series de tiempo, la cual será empleada en el análisis de dos series de tiempo reales. Además, se incluye un estudio de simulación para ilustrar y evaluar los procesos de estimación y predicción de los modelos.

Abstract

The study of time series is a fundamental tool in the analysis of data that evolve over time, allowing us to model and predict phenomena in fields such as economics, meteorology, engineering or social sciences.

This Final Degree Thesis deals with the analysis of time series from a classical statistical perspective, considering that the observed series are realisations of stochastic processes. Autoregressive (AR), moving average (MA), mixed (ARMA), integrated (ARIMA) and seasonal (SARIMA) models are presented in detail, explaining their mathematical formulation, parameter estimation methods and associated forecasting techniques. A methodology for time series analysis is also proposed, which will be used in the analysis of two real time series. In addition, a simulation study is included to illustrate and evaluate the estimation and forecasting processes of the models.

Capítulo 1

Motivación y ejemplos de series de tiempo

Una serie de tiempo es una secuencia de valores medidos regularmente a lo largo del tiempo. Por ejemplo, el número total de visitantes de una página web cada minuto a lo largo de un año es una serie de tiempo.

El análisis de series de tiempo permite comprender el comportamiento de un fenómeno a lo largo del tiempo, detectar patrones recurrentes, y predecir su comportamiento futuro. En el ejemplo anterior, interesa predecir el número de visitantes en los próximos minutos o días, para ajustar las capacidades de los servidores en función de la demanda. De esta forma, se evitan caídas del sistema, mejorando la experiencia del usuario y reduciendo el riesgo de perder visitas o ventas.

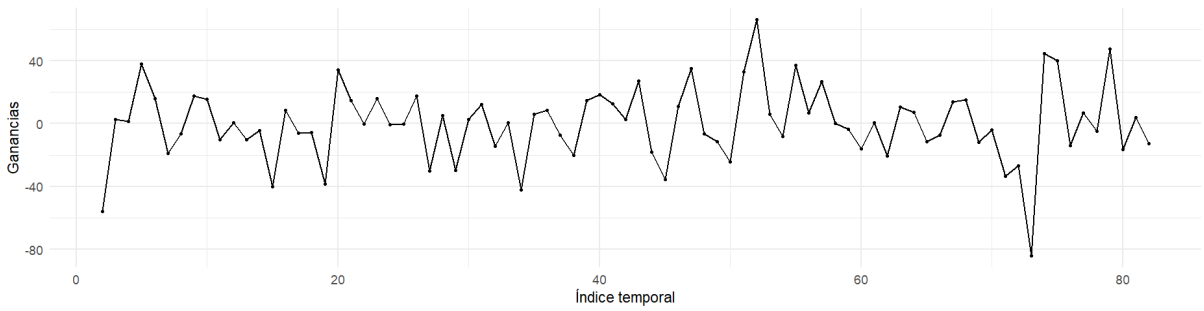

Figura 1.1: Ganancias del SP500 con respecto al día anterior en el primer cuatrimestre del año 2000. Datos obtenidos de [9].

En la Figura 1.1 se muestra un ejemplo de serie de tiempo, en este caso, las ganancias del índice bursátil SP500 con respecto al día anterior en el primer cuatrimestre del año 2000. El análisis de

esta serie es de gran interés en el ámbito financiero, ya que modelando su dinámica se podrían predecir comportamientos futuros, apoyando así la toma de decisiones estratégicas en inversiones y la planificación financiera. Por otra parte, en dicho gráfico se observa que los valores de la serie oscilan alrededor de un valor constante, y parecen tener una variabilidad estable a lo largo del tiempo. A este tipo de series se les denomina estacionarias. El concepto de estacionariedad será definido formalmente en el Capítulo 2.

No obstante, en la práctica, muchas series de tiempo no son estacionarias. Un caso común ocurre cuando la serie presenta tendencia. En la serie de tiempo mostrada en la Figura 1.2 se muestran los valores del SP500 desde el 2 de octubre de 2023 hasta el 30 de agosto de 2024, con frecuencia diaria. En este caso, se observa que la serie presenta una tendencia creciente.

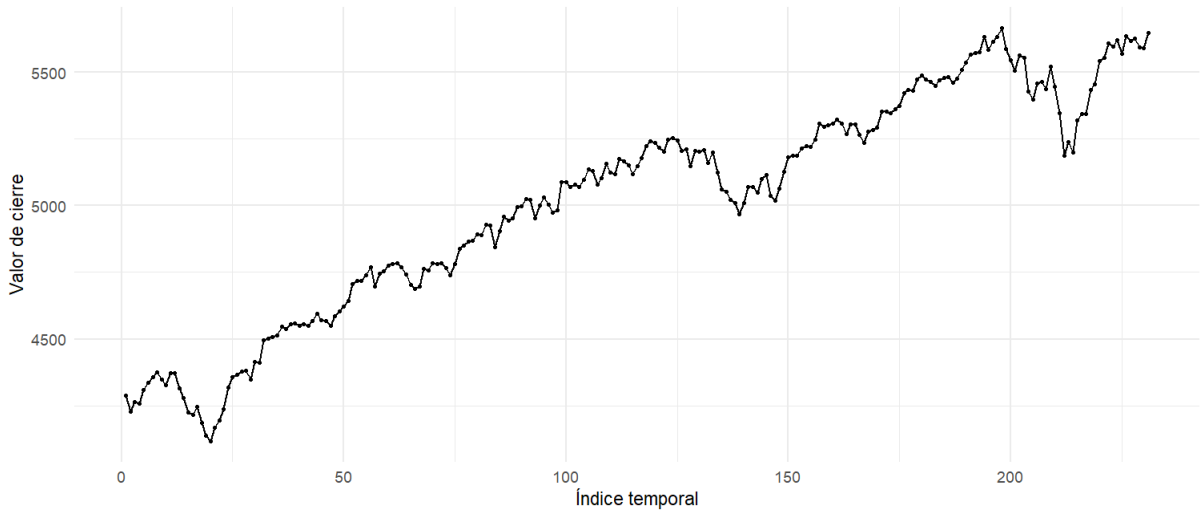

Figura 1.2: Serie de tiempo del SP500 desde el 2 de octubre de 2023 hasta el 30 de agosto de 2024. Datos obtenidos de [9].

Otro motivo común de no estacionariedad es la presencia de estacionalidad, que se refiere a patrones que se repiten en intervalos regulares. Por ejemplo, en la Figura 1.3 se grafica la serie de tiempo correspondiente al número de millones de pasajeros que aterrizan en la isla Tenerife cada mes desde enero de 1999 hasta diciembre de 2004. Se observa que la serie presenta un patrón estacional, ya que el número de pasajeros tiende a aumentar en los meses de verano y disminuir en los meses de invierno. El interés en analizar esta serie radica en poder anticipar la demanda de pasajeros para planificar recursos o ajustar precios de vuelos según la demanda esperada, por ejemplo.

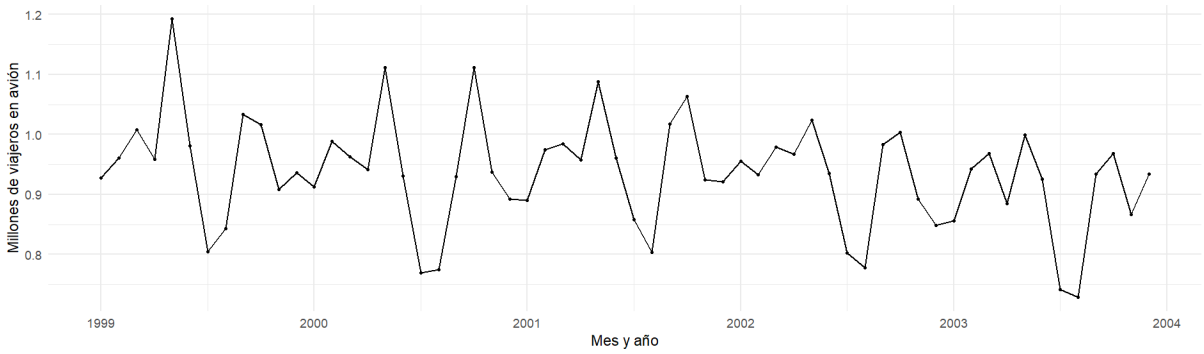

Figura 1.3: Serie de tiempo del número de millones de pasajeros que aterrizan en la isla Tenerife cada mes desde enero de 1999 hasta diciembre de 2004. Datos obtenidos de [8].

En el último capítulo de este Trabajo Fin de Grado se analizarán otras dos series de tiempo reales. La primera corresponde a los valores del IBEX 35, de interés similar a los del SP500. La segunda recoge el consumo mensual de electricidad en Estados Unidos, cuyo análisis puede ser útil para predecir la demanda y planificar la producción energética.

En el contexto de este Trabajo Fin de Grado se modelarán las series de tiempo suponiendo que son realizaciones muestrales de un proceso estocástico, en concreto, de procesos AR, MA, ARMA, ARIMA y SARIMA. Estos modelos permiten describir la dinámica de las series de tiempo y realizar predicciones sobre su comportamiento futuro.

1.1. Objetivos de este Trabajo Fin de Grado

El presente Trabajo Fin de Grado tiene los siguientes objetivos:

- Presentar los modelos clásicos de series de tiempo AR, MA, ARMA, ARIMA y SARIMA, explicando su formulación, métodos de estimación y predicción.
- Realizar un estudio de simulación para ilustrar los procesos de estimación y predicción.
- Presentar una metodología para el análisis de series de tiempo, de tal forma que las decisiones tomadas o las herramientas usadas en cada paso estén justicadas y explicadas.
- Proporcionar algún ejemplo de serie de tiempo real, realizando un análisis completo de la misma, utilizando la metodología anteriormente propuesta.

1.2. Estructura del trabajo

Este Trabajo Fin de Grado se estructura en cuatro capítulos. En este primer capítulo, se han introducido de forma cualitativa los conceptos de serie de tiempo, estacionariedad, tendencia y estacionalidad utilizando ejemplos de datos reales, y tratando de motivar el estudio de las series de tiempo.

En el segundo capítulo, se revisarán los modelos clásicos de series de tiempo, como AR, MA, ARMA, ARIMA y SARIMA. Se explicará su formulación matemática, los métodos de estimación de sus parámetros y las técnicas de predicción asociadas a cada modelo. Asimismo, se presentará una metodología para el análisis de series de tiempo, que incluye la identificación del modelo adecuado, la estimación de sus parámetros y la validación del modelo.

En el tercer capítulo, se presentará un estudio de simulación que ilustrará los procesos de estimación y predicción. Se generarán artificialmente series de tiempo y se ajustarán los modelos clásicos a estas series, analizando la bondad de los estimadores y predicciones.

Por último, en el cuarto capítulo se presentarán dos ejemplos de series de tiempo reales. Para cada uno de ellas, se aplicará la metodología propuesta en el segundo capítulo para analizar la serie, estimar sus parámetros y realizar predicciones. Cabe destacar que tanto el estudio de simulación como el análisis de las series de tiempo se realizaron utilizando R.

Capítulo 2

Revisión de los modelos clásicos. Formulación y estimación

En este capítulo se introducen conceptos básicos para el análisis de series de tiempo, como son la definición de serie de tiempo, proceso estocástico, estacionariedad, y las funciones de medias, varianzas y autocorrelaciones. Posteriormente, se presentan los procesos AR, MA, ARMA, ARIMA y SARIMA, los cuales son modelos clásicos de las series de tiempo. A continuación se presenta la estimación de estos modelos, y se define un predictor óptimo para llevar a cabo la predicción de los valores futuros de la serie. Por último, se propone la metodología Box-Jenkins para el análisis de series de tiempo.

A continuación se presentan las definiciones y conceptos básicos para el análisis de tiempo, basados en [1, 2, 3, 5].

Definición 2.1 (Serie de tiempo)**.** Una serie de tiempo es un conjunto de T observaciones $\{x_t\}_{t=1}^{T}$, medidas cada una ellas en un tiempo específico t de forma regular.

A la hora de analizar una serie de tiempo, interesa establecer un modelo matemático que permita explicar el comportamiento de la serie. Para ello, es común suponer que la serie es una realización muestral de un proceso estocástico.

Definición 2.2 (Proceso estocástico)**.** Un proceso estocástico $\{X_t\}$ es un conjunto de variables aleatorias definidas en un espacio de probabilidad común $(\Omega, \mathcal{F}, \mathbb{P})$, que toman valores en un espacio métrico S, y que están indexadas en $t \in \mathcal{T}$.

Observación 2.3. En adelante, aunque no se haga explícito, se entenderá que $t \in \mathcal{T}$, y se denotará por $\{x_t\}$ a la serie de tiempo (realización muestral) del proceso estocástico $\{X_t\}$.

Es decir, la serie de tiempo $(x_1, \ldots, x_T)$ es una realización muestral (muestra de tamaño 1) del vector aleatorio $(X_1, \ldots, X_T)$. Además, las distribuciones finito-dimensiones son una clase

caracterizadora de la probabilidad, ya que un proceso queda completamente caracterizado si se define la distribución conjunta de cualquier subconjunto de variables de $\{X_t\}$. En concreto, son de especial interés las distribuciones marginales de cada variable, siendo necesario definir las siguientes funciones para estudiar sus propiedades:

Definición 2.4 (Función de medias)**.** Sea $\{X_t\}$ un proceso estocástico tal que $\mathbb{E}(X^2) < \infty$, se define la función de medias como

$$\mu_t = \mathbb{E}(X_t).$$

Definición 2.5 (Función de varianzas)**.** Sea $\{X_t\}$ un proceso estocástico tal que $\mathbb{E}(X^2) < \infty$, se define la función de varianzas como

$$\sigma_t^2 = \mathrm{Var}(X_t).$$

Para medir el grado de dependencia lineal entre las distintas variables aleatorias que conforman el proceso, se define la función de autovarianzas.

Definición 2.6 (Función de autocovarianzas)**.** Sea $\{X_t\}$ un proceso estocástico tal que $\mathbb{E}(X^2) < \infty$, se define la función de autocovarianzas como

$$\gamma(s,t) = \mathrm{Cov}(X_s, X_t) = \mathbb{E}[(X_s - \mu_s)(X_t - \mu_t)].$$

La función de autocovarianzas no sirve para comparar series o procesos medidos en diferentes unidades. Por eso, es necesario definir una nueva medida adimensional de la dependencia lineal.

Definición 2.7 (Función de autocorrelaciones simples)**.** Sea $\{X_t\}$ un proceso estocástico tal que $\mathbb{E}(X^2) < \infty$, se define la función de autocorrelaciones simples (fas) como

$$\rho(s,t) = \frac{\gamma(s,t)}{\sigma_s \sigma_t}.$$

Definición 2.8 (Función de autocorrelaciones parciales)**.** Sea $\{X_t\}$ un proceso estocástico tal que $\mathbb{E}(X^2) < \infty$, se define la función de autocorrelaciones parciales (fap) como

$$\alpha(s,t) = \frac{\mathrm{Cov}(X_s - \hat{X}_s^{(s,t)}, X_t - \hat{X}_t^{(s,t)})}{\sqrt{\mathrm{Var}(X_s - \hat{X}_s^{(s,t)})\mathrm{Var}(X_t - \hat{X}_t^{(s,t)})}},$$

donde $\hat{X}_j^{(s,t)}$ denota el mejor predictor lineal de X_j construido a partir de las variables medidas en los instantes comprendidos entre s y t (sin considerar ni s ni t). La función de autocorrelaciones parciales puede interpretarse como una medida de la dependencia lineal entre X_s y X_t después de haberle sustraído el efecto lineal que sobre cada una de ellas ejercen las variables medidas en los instantes comprendidos en s y t. Posteriormente se explicará cómo calcular los valores de esta función para un tipo de procesos concreto.

Para estimar las cinco funciones anteriores, sería necesario de disponer de varias realizaciones del proceso, es decir, de una muestra de un cierto tamaño (mayor que 1) del vector $(X_1, \ldots, X_T)$. Sin embargo, en muchos casos esto no es posible. Como solución, se le exigirá al proceso que ciertas propiedades no dependan del instante temporal, es decir, que el proceso sea estacionario.

Definición 2.9 (Estacionariedad débil)**.** Un proceso estocástico $\{X_t\}$ es débilmente estacionario, si su media, varianza y estructura de covarianzas no varían a lo largo del tipo, i.e., si

(i) μ_t no depende de t, y por lo tanto $\mu \equiv \mu_t$,

(ii) $\gamma(t+h, t)$ no depende de t para cualquier valor de $h \geq 0$. En este caso, $\gamma(h) \equiv \gamma(t+h, t)$ $\forall t$.

Observación 2.10. A lo largo de este Trabajo Fin de Grado, toda referencia a estacionariedad se entenderá, salvo indicación contraria, como estacionariedad débil.

Observación 2.11. Se dirá que una serie de tiempo es estacionaria si es una realización de un proceso estacionario.

Observación 2.12. La idea intuitiva que se puede extraer de la definición anterior, es que bajo estacionariedad débil la dependencia entre dos observaciones depende únicamente de la distancia entre los instantes temporales donde fueron observadas, y no de estos instantes.

Observación 2.13. La clasificación de una serie como estacionaria o no depende del período de observación, ya que una serie puede ser estacionaria en un período y no serlo en otro.

Por lo tanto, en el caso de tener estacionariedad débil, se puede simplificar la notación de las funciones anteriores:

- $\gamma_h \equiv \gamma(s, t)$, donde $h = |s - t|$.
- $\rho_h \equiv \dfrac{\gamma_h}{\gamma_0}$
- $\alpha_h \equiv \alpha(h, 0) = \dfrac{\operatorname{Cov}\left(X_h - \hat{X}_h^{(h,0)}, X_0 - \hat{X}_0^{(h,0)}\right)}{\sqrt{\operatorname{Var}\left(X_h - \hat{X}_h^{(h,0)}\right) \operatorname{Var}\left(X_0 - \hat{X}_0^{(h,0)}\right)}}.$

Para un proceso estacionario se puede calcular más fácilmente los valores de la función de autocorrelaciones parciales.

Proposición 2.14. La función de autocorrelaciónes parciales en el retardo h de un proceso estacionario $\{X_t\}$ de media nula viene dada por la última componente de $\boldsymbol{\phi}_h$, i.e.,

$$\alpha_h = \phi_{hh}, \quad h \geq 1,$$

donde $\boldsymbol{\phi}_h$ son los coeficientes del mejor predictor lineal de X_{h+1} en términos de $X_1, \ldots, X_h$, es decir, $\sum_{j=1}^{h} \phi_{hj} X_{h+1-j}$, tal y como se describe en la Sección 2.5.1. La demostración de esta proposición se puede consultar en el Capítulo 5 de [3].

A continuación se definirá un proceso que jugará el papel análogo a los errores el modelo de regresión lineal clásico.

Ejemplo 2.15 (Ruido blanco)**.** El proceso $\{Z_t\}$ se dice ruido blanco si las variables aleatorias que lo conforman están incorreladas, tienen media cero, y varianza σ^2. Como consecuencia de esta definición, se tiene que el proceso es estacionario. Por una parte, si en vez de incorrelación se tiene independencia, se denominará ruido blanco independiente. Por otra parte, si el proceso es gaussiano, se denominará ruido blanco gaussiano. En este último caso, el hecho de ser incorrelado implicaría que es independiente, por propiedades de la distribución normal.

Observación 2.16. Es común denominar innovaciones a los términos de ruido blanco que aparecen en la representación de un proceso estocástico. Intuitivamente, representan la "nueva información" o el "shock" aleatorio que afecta al sistema en cada instante de tiempo.

A continuación se presentan diferentes tipos de procesos estocásticos de gran interés.

Definición 2.17 (Proceso lineal)**.** $\{X_t\}$ es un proceso lineal si se puede representar como

$$X_t = c + \sum_{j=-\infty}^{\infty} \psi_j Z_{t-j} \quad \forall t, \tag{2.1}$$

donde c es una constante, $\{Z_t\}$ es ruido blanco, y $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$. Es decir, un proceso lineal es aquel que se puede expresar en función de sus innovaciones.

Definición 2.18 (Proceso causal)**.** Es aquel que admite una representación del tipo

$$X_t = c + \sum_{j=0}^{\infty} \psi_j Z_{t-j} \forall t, \tag{2.2}$$

donde c es una constante, $\{Z_t\}$ es ruido blanco, y $\sum_{j=0}^{\infty} |\psi_j| < \infty$. Es decir, un proceso causal es aquel que se puede expresar solamente en función de sus innovaciones pasadas y presentes, sin requerir información futura.

Definición 2.19 (Proceso invertible)**.** Es aquel que admite una representación del tipo

$$X_t = c + Z_t + \sum_{j=1}^{\infty} \pi_j X_{t-j} \forall t, \tag{2.3}$$

donde c es una constante, $\{Z_t\}$ es ruido blanco, y $\sum_{j=0}^{\infty} |\pi_j| < \infty$. Es decir, un proceso invertible es aquel que se puede expresar en función de sus valores pasados, y de su innovación presente.

Proposición 2.20 (Descomposición de Wald)**.** Sea $\{X_t\}$ un proceso débilmente estacionario de media finita c, que no contiene componentes deterministas, entonces $\{X_t\}$ puede ser reescrito como un proceso causal:

$$X_t = c + \sum_{j=0}^{\infty} \psi_j Z_{t-j} \ \forall t,$$

tal que $\psi_0 = 1$ y $\sum_{j=0}^{\infty} |\psi_j|^2 < \infty$, donde $\{Z_t\}$ es ruido blanco.

Observación 2.21. La Descomposición de Wald garantiza que cualquier proceso débilmente estacionario o bien es lineal, o bien puede ser transformado para que lo sea (sin más que sustraerle la componente determinista).

2.1. Estimación de μ, $\gamma(\cdot)$ y $\rho(\cdot)$.

Cuando se desconozca el proceso estocástico estacionario que originó una serie de tiempo $\{x_t\}$ será necesario estimar las funciones anteriores, tal y como se describe a continuación.

2.1.1. Estimación de μ.

Es sencillo probar que un estimador insesgado de la media μ es la media muestral:

$$\hat{\mu} = \frac{1}{T} \sum_{t=1}^{T} x_t.$$

Al ser insesgado, su error cuadrático medio coincide con su varianza

$$\mathbb{E}[(\hat{\mu} - \mu)^2] = \mathrm{Var}(\hat{\mu}) = \frac{1}{T} \left(\sigma^2 + 2 \sum_{h=1}^{T} \left(1 - \frac{h}{T} \right) \gamma_h \right). \tag{2.4}$$

Observación 2.22. Para que $\hat{\mu}$ sea consistente, es condición necesaria (pero no suficiente) que $\gamma_h \xrightarrow{h \to \infty} 0$. Para que esta condición sea también suficiente, es necesario que el proceso sea estacionario.

Por otra parte, para hacer inferencia sobre la media muestral será necesario conocer su distribución. En el caso de un proceso gaussiano, se conoce su distribución exacta,

$$\hat{\mu} \in N \left(\mu, \ \frac{1}{T} \left(\sigma^2 + 2 \sum_{h=1}^{T} \left(1 - \frac{h}{T} \right) \gamma_h \right) \right).$$

Como generalmente no se conoce γ_h, la varianza de $\hat{\mu}$ se aproximará por

$$\frac{1}{T} \left(\hat{\sigma}^2 + 2 \sum_{h=1}^{T} \left(1 - \frac{h}{T} \right) \hat{\gamma}_h \right).$$

2.1.2. Estimación de $\gamma(\cdot)$ y $\rho(\cdot)$.

Para una realización muestral $\{x_t\}$, dos posibles estimadores de la función de autocovarianzas serían

$$\tilde{\gamma}_h = \frac{1}{T-h}\sum_{t=1}^{T-|h|}(x_{|h|+t}-\hat{\mu})(x_t-\hat{\mu}) \quad \text{y} \quad \hat{\gamma}_h = \frac{1}{T}\sum_{t=1}^{T-|h|}(x_{|h|+t}-\hat{\mu})(x_t-\hat{\mu}).$$

A pesar de que ambos son sesgados y asintóticamente insesgados, es preferible el segundo por dos motivos. En primer lugar, da lugar a un error cuadrático medio menor. En segundo lugar, la matriz de autocovarianzas muestrales $\hat{\Gamma}_h$ es siempre definida no negativa, y esto es necesario para que las covarianzas muestrales puedan corresponderse a un proceso estacionario.

A partir de $\hat{\gamma}_h$, se propone el siguiente estimador para la función de autocorrelaciones simples:

$$\hat{\rho}_h = \frac{\hat{\gamma}_h}{\hat{\gamma}_0}. \tag{2.5}$$

En la sección 7.3 de [3] se demuestra que, para un proceso estacionario

$$\widehat{\boldsymbol{\rho}}_h = (\hat{\rho}_1, \ldots, \hat{\rho}_h) \xrightarrow{d} N_h(\boldsymbol{\rho}_h, T^{-1}W), \tag{2.6}$$

donde W es una matriz de covarianzas cuyos elementos vienen dados por la fórmula de Bartlett:

$$w_{ij} = \sum_{h=1}^{\infty}\{\rho_{h+i}+\rho_{h-i}-2\rho_i\rho_h\} \times \{\rho_{h+j}+\rho_{h-j}-2\rho_i\rho_j\}.$$

2.1.3. Estimación de $\alpha(\cdot)$.

Teniendo en cuenta la Proposición 2.14, para estimar α_h basta estimar ϕ_h, cuya estimación se presentará en la Sección 2.5.1.

2.2. Convergencia de series de variables aleatorias

Cuando se presentaron los procesos lineales (2.1), causales (2.2) e invertibles (2.3) se introdujo de una suma infinita de variables aleatorias. A continuación se muestran un par de resultados, tomados de [3], que dan una condición suficiente para garantizar la convergencia de una serie de variables aleatorias.

Definición 2.23 (Operador B)**.** Se define el operador B como $BX_t = X_{t-1}$. La potencia j-ésima de B, B^j, se define como $B^j(X_t) = X_{t-j}$.

Teorema 2.24. Sea $\{X_t\}$ una sucesión de variables aleatorias tales que $\sup_t \mathbb{E}\,|X_t| < \infty$ y $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$. Entonces, la serie

$$\psi(B)X_t = \sum_{j=-\infty}^{\infty} \psi_j B^j X_t = \sum_{j=-\infty}^{\infty} \psi_j X_{t-j},$$

converge absolutamente con probabilidad uno. Además, si $\sup_t E\,|X_t|^2 < \infty$, entonces la convergencia también se produce en media cuadrática al mismo límite.

Demostración. Solo se demostrará la primera afirmación. Se tiene que

$$\mathbb{E}\left(\sum_{j=-\infty}^{\infty} |\psi_j|\,|X_{t-j}|\right) = \lim_{n\to\infty} \mathbb{E}\left(\sum_{j=-n}^{n} |\psi_j|\,|X_{t-j}|\right) \leq \lim_{n\to\infty}\left(\sum_{j=-n}^{n} |\psi_j|\right) \cdot \sup \mathbb{E}\,|X_t| < \infty,$$

donde la primera igualdad está justificada por un corolario del teorema de la convergencia monótona (Corolario I.3 del Apéndice I). Entonces, $\sum_{j=-\infty}^{\infty} |\psi_j|\,|X_{t-j}|$ y $\psi(B)X_t = \sum_{j=-\infty}^{\infty} \psi_j X_{t-j}$ convergen en media, y por lo tanto, en probabilidad[1]. □

Proposición 2.25. Sea $\{X_t\}$ un proceso estacionario con función de autocovarianzas $\gamma_X(\cdot)$. Si $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$, entonces el proceso

$$Y_t = \psi(B)X_t = \sum_{j=-\infty}^{\infty} \psi_j X_{t-j} \tag{2.7}$$

es estacionario con función de autocovarianzas

$$\gamma_Y(h) = \sum_{j=-\infty}^{\infty} \sum_{k=-\infty}^{\infty} \psi_j \psi_k \gamma_X(h+k-j).$$

Para el caso particular de que $\{X_t\}$ sea un proceso lineal,

$$\gamma_Y(h) = \sigma^2 \sum_{j=-\infty}^{\infty} \psi_j \psi_{j+h}.$$

Demostración. Por ser $\{X_t\}$ estacionario, $\mathbb{E}|X_t| \leq (\mathbb{E}|X_t|^2)^{1/2} < \infty$, por lo que aplicando la Proposición 2.24, se demuestra que la serie (2.7) es absolutamente convergente tanto en probabilidad como en media cuadrática. La estacionariedad de $\{Y_t\}$, se sigue de que

$$\mathbb{E}(Y_t) \overset{(*)}{=} \lim_{n\to\infty} \sum_{j=-n}^{n} \psi_j \mathbb{E}(X_{t-j}) = \left(\sum_{j=-\infty}^{\infty} \psi_j\right) \mathbb{E}(X_t)$$

y

$$\begin{aligned}\mathbb{E}(Y_{t+h}Y_t) &\overset{(*)}{=} \lim_{n\to\infty} \mathbb{E}\left[\left(\sum_{j=-n}^{n} \psi_j X_{t+h-j}\right)\left(\sum_{k=-n}^{n} \psi_k X_{t-k}\right)\right] = \sum_{j=-\infty}^{\infty}\sum_{k=-\infty}^{\infty} \psi_j\psi_k \mathbb{E}(X_{t+h-j}X_{t-k}) \\ &= \sum_{j=-\infty}^{\infty}\sum_{k=-\infty}^{\infty} \psi_j\psi_k(\gamma_X(h-j+k) + \mathbb{E}(X_t)^2),\end{aligned}$$

[1]Conceptos vistos en la asignatura de Probabilidad y Estadística del Grado en Matemáticas.

donde en las igualdades (*) son consecuencia de la Proposición I.5 del Apéndice I. □

Corolario 2.26. Un operador como $\psi(B) = \sum_{j=-\infty}^{\infty} \psi_j B^j$, con $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$, hereda las propiedades algebraicas de las series de potencias, cuando son aplicadas a procesos estacionarios. Más formalmente, si $\sum_{j=-\infty}^{\infty} |\alpha_j| < \infty$, $\sum_{j=-\infty}^{\infty} |\beta_j| < \infty$, $\alpha(B) = \sum_{j=-\infty}^{\infty} \alpha_j B^j$, $\beta(B) = \sum_{j=-\infty}^{\infty} \beta_j B^j$, y $\psi(B) = \sum_{j=-\infty}^{\infty} \psi_j B^j$, donde

$$\psi_j = \sum_{k=-\infty}^{\infty} \alpha_k \beta_{j-k} = \sum_{k=-\infty}^{\infty} \beta_k \alpha_{j-k},$$

entonces $\alpha(B)\beta(B)X_t$ está bien definido y $\alpha(B)\beta(B)X_t = \beta(B)\alpha(B)X_t = \psi(B)X_t$.

2.3. Procesos estacionarios

Para modelar series de tiempo, se supone que estas son realizaciones de un proceso estocástico. En esta sección se presentarán tres procesos estacionarios: el proceso de medias móviles (MA), el proceso autorregresivo (AR) y el proceso autorregresivo de medias móviles (ARMA), el cual es una combinación de los dos anteriores.

2.3.1. Procesos de medias móviles (MA)

Definición 2.27 (Proceso MA(q))**.** $\{X_t\}$ es un proceso de medias móviles de orden q (MA(q)) si para todo t verifica la siguiente ecuación,

$$X_t = c + Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \ldots + \theta_q Z_{t-q} \iff X_t = c + \theta(B) Z_t$$

donde $\{Z_t\}$ es ruido blanco, $\theta_1, \ldots, \theta_q$ ($\theta_q \neq 0$) son constantes reales, $\theta(z) = 1 + \theta_1 z + \theta_2 z^2 + \ldots + \theta_q z^q$ es un polinomio complejo con coeficientes reales, y c es la media del proceso.

Como se puede observar, esta definición es un caso particular de la de proceso lineal, en la que solo una cantidad finita de los coeficientes ψ_j son no nulos. Por lo tanto, ya se puede afirmar directamente que los procesos MA(q) son estacionarios, causales y con función de autocovarianzas

$$\gamma_h = \begin{cases} \sigma^2 \displaystyle\sum_{j=0}^{q-|h|} \theta_j \theta_{j+h} & \text{si } |h| \leq q, \\ 0 & \text{si } |h| > q, \end{cases} \tag{2.8}$$

donde θ_0 vale 1.

Además, un proceso MA(q) será invertible si y solamente si $\theta(z)$ no tiene ninguna raíz de módulo menor o igual que uno.

A la vista de (2.8), la función de autocovarianzas de un proceso MA(q) se anula para cualquier retardo mayor que q, y es distinto de cero en el retardo q. Esta característica permitirá identificar modelos de medias móviles a partir de los valores de la función de autocorrelaciones muestrales, planteando un contraste de hipótesis donde la hipótesis nula es que el proceso es MA(q) y la alternativa es que no lo es.

En la Sección 2.1.2 se dio una distribución aproximada para el vector $\hat{\boldsymbol{\rho}}_h$ (2.6), a partir de la cual se puede deducir que para un h concreto,

$$\hat{\rho}_h \xrightarrow{d} N\left(\rho_h,\ \frac{w_{hh}}{T}\right),$$

donde w_{hh} es la varianza de $\hat{\rho}_h$ calculada mediante la fórmula de Bartlett, y bajo la hipótesis nula de que el proceso es MA(q) (y por lo tanto $\rho_h = 0\ \forall h > q$), se tiene que:

$$w_{hh} = \frac{1 + 2\rho_1^2 + \ldots + \rho_q^2}{T} \quad \forall h > q.$$

Entonces, para un nivel de significación individual aproximado del 5 %, no habría evidencias en contra de la hipótesis nula si $\forall h > q$

$$\hat{\rho}_h \in \left(-1.96\sqrt{\frac{1 + 2\left(\hat{\rho}_1^2 + \cdots + \hat{\rho}_q^2\right)}{T}},\ 1.96\sqrt{\frac{1 + 2\left(\hat{\rho}_1^2 + \cdots + \hat{\rho}_q^2\right)}{T}}\right).$$

2.3.2. Procesos autorregresivos (AR)

A continuación se definen los procesos autorregresivos, que expresan el valor del proceso en un instante t como una combinación lineal de su valor en los p instantes anteriores, más un valor aleatorio (la innovación). Es decir, generalizan la idea del modelo de regresión lineal para representar la dependencia temporal.

Definición 2.28 (Proceso AR(p))**.** $\{X_t\}$ es un proceso autorregresivo de orden p (AR(p)) si es estacionario, y para todo t se verifica la siguiente ecuación

$$X_t = c + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \ldots + \phi_p X_{t-p} + Z_t \iff \phi(B)X_t = c + Z_t,$$

donde $\{Z_t\}$ es ruido blanco (Ejemplo 2.15), $\phi_1, \ldots, \phi_p$ ($\phi_p \neq 0$) son constantes reales, $\phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \ldots - \phi_p z^p$ es un polinomio complejo con coeficientes reales y c es una constante real tal que $c = \mu(1 - \phi_1 - \ldots - \phi_p)$, donde μ es la media del proceso.

Se puede demostrar que la función de autocorrelaciones parciales es nula para todo $h > p$. Por lo tanto, esta característica podrá ser útil para identificar el orden del proceso AR generador de una serie de tiempo. De hecho, en [4] se demuestra que para un modelo autorregresivo de orden p, $\{\hat{\alpha}_h\}_{h>p}$ son aproximadamente independientes y normales de media 0, con varianza $1/T$, donde T es el tamaño muestral.

2.3.3. Procesos autorregresivos de medias móviles (ARMA)

La combinación de un proceso autorregresivo y un proceso de medias móviles da lugar a proceso mixto, denominado proceso autorregresivo de medias móviles, o ARMA.

Definición 2.29 (Proceso ARMA(p,q))**.** $\{X_t\}$ es un proceso ARMA(p,q) si es estacionario, y para todo t verifica la siguiente ecuación

$$X_t = c + \phi_1 X_{t-1} + \ldots + \phi_p X_{t-p} + Z_t + \theta_1 Z_{t-1} + \ldots + \theta_q Z_{t-q} \iff \phi(B)X_t = c + \theta(B)Z_t \quad (2.9)$$

donde $\{Z_t\}$ es ruido blanco, y $c, \phi_1, \ldots, \theta_p, \theta_1, \ldots, \theta_q$ ($\phi_p \neq 0 \neq \phi_q$) son constantes reales.

A continuación se demuestran varios resultados, tomados de [3], en los que se supondrá sin pérdida de generalidad que el proceso tiene media nula (y por lo tanto $c = 0$). Las demostraciones que se presentan a continuación han sido adaptadas de [3], completando algunos pasos que en el texto original se omiten o se dan por obvios, con el fin de hacerlas más comprensibles.

Teorema 2.30. Un proceso ARMA(p,q), $\{X_t\}$, cuyos polinomios $\phi(\cdot)$ y $\theta(\cdot)$ no tienen ceros comunes, es causal si y solamente si $\phi(z) \neq 0$ para todo $z \in \mathbb{C}$ tal que $|z| \leq 1$.

Demostración. Si $\phi(z) \neq 0$ para todo $z \in \mathbb{C}$ tal que $|z| \leq 1$, como el conjunto de los de ceros de $\phi(z)$ es cerrado, existe un $\varepsilon > 0$ tal que $\phi(z) \neq 0$ en el disco abierto de centrado en 0 y con radio $1+\varepsilon$, siendo entonces la función compleja $1/\phi(z)$ diferenciable en dicho disco. Por lo tanto, existe una sucesión $\{\xi_j\}_{j\in\mathbb{N}}$ tal que

$$\frac{1}{\phi(z)} = \sum_{j=0}^{\infty} \xi_j z^j = \xi(z), \quad \forall |z| < 1+\varepsilon.$$

Teniendo en cuenta que dicha serie es convergente para $\forall |z| < 1+\varepsilon$, se tiene que $\xi_j r^j \xrightarrow{j\to\infty} 0$ para todo $r < 1+\varepsilon$. En concreto, $\xi_j(1+\varepsilon/2)^j \xrightarrow{j\to\infty} 0$. Consecuentemente, $\exists K > 0$ tal que $|\xi_j| \leq K(1+\varepsilon/2)^{-j}$ $\forall j \in \mathbb{N}$. Como la serie geométrica es convergente, por el criterio de comparación de series se puede concluir finalmente que $\sum_{j=0}^{\infty} |\xi_j| < \infty$ y que $\xi(z)\phi(z) = 1$ para $|z| \leq 1$. Entonces, se puede aplicar el operador $\xi(B)$ a ambos lados de la ecuación $\phi(B)X_t = \theta(B)Z_t$ para obtener

$$X_t = \xi(B)\theta(B)Z_t = \sum_{j=0}^{\infty} \psi_j Z_{t-j},$$

donde los coeficientes $\{\psi_j\}_{j=0}^{\infty}$ se definen a partir de la relación

$$\psi(z) = \sum_{j=0}^{\infty} \psi_j z^j = \frac{\theta(z)}{\phi(z)}, \quad |z| \leq 1. \quad (2.10)$$

Para probar el recíproco, si $\{X_t\}$ es causal, $X_t = \sum_{j=0}^{\infty} \psi_j Z_{t-j}$ para alguna sucesión $\{\psi_j\}$, $\sum_{j=0}^{\infty} |\psi_j| < \infty$. Definiendo $\eta(z) := \phi(z)\psi(z) = \sum_{j=0}^{\infty} \eta_j z^j$, $|z| \leq 1$, se tiene que

$$\sum_{j=0}^{q} \theta_j Z_{t-j} = \theta(B)Z_t = \phi(B)X_t = \phi(B)\psi(B)Z_t = \eta(B)Z_t = \sum_{j=0}^{\infty} \eta_j Z_{t-j}$$

Para comparar los coeficientes de ambos lados, se considera la covarianza de cada lado con Z_{t-k}. Como $\{Z_t\}$ es un proceso de ruido blanco con media cero y varianza constante, sabemos que $\mathrm{Cov}(Z_{t-j}, Z_{t-k}) = 0$ para $j \neq k$ y $\mathrm{Cov}(Z_{t-j}, Z_{t-k}) = \sigma^2$ para $j = k$. Aplicando esto, se obtiene que:

$$\mathrm{Cov}\left(\sum_{j=0}^{q} \theta_j Z_{t-j}, Z_{t-k}\right) = \theta_k \sigma^2, \quad \text{y} \quad \mathrm{Cov}\left(\sum_{j=0}^{\infty} \eta_j Z_{t-j}, Z_{t-k}\right) = \eta_k \sigma^2.$$

Por lo tanto, para cada $k = 0, 1, \ldots, q$, se sigue que $\theta_k = \eta_k$, y como $\theta_k = 0$ si $k > q$, también $\eta_k = 0$ para $k > q$. Entonces,

$$\theta(z) = \eta(z) = \phi(z)\psi(z), \quad |z| \leq 1.$$

Como $\theta(z)$ y $\phi(z)$ no tienen ceros en común, y como $|\psi(z)| < \infty$ para $|z| \leq 1$, se concluye que $\phi(z) \neq 0 \ \ \forall |z| \leq 1$. □

Observación 2.31. Un proceso ARMA(p, q) causal es también estacionario.

Cálculo de los coeficientes ψ_j.

Los coeficientes ψ_j definidos en (2.10) se pueden calcular igualando los coeficientes de z^j de la ecuación

$$\psi(z)\phi(z) = \theta(z) \iff (1 + \psi_1 z + \psi_2 z^2 + \ldots)(1 - \phi_1 z - \ldots - \phi_p z^p) = (1 + \theta_1 z + \ldots + \theta_q z^q).$$

Entonces,

$$\theta_j = \psi_j - \sum_{k=1}^{j} \phi_k \psi_{j-k}, \quad 0 \leq j < \text{máx}(p, q+1).$$

Las ecuaciones resultantes serían,

$$\begin{aligned}
\psi_0 &= \theta_0 = 1 \\
\psi_1 &= \theta_1 + \psi_0 \phi_1 = \theta_1 + \phi_1 \\
\psi_2 &= \theta_2 + \psi_0 \phi_2 + \psi_1 \phi_1 = \theta_2 + \phi_2 + \theta_1 \phi_1 + \phi^2 \\
&\vdots
\end{aligned}$$

Al saber calcular los coeficientes ψ_j, ya se puede calcular la función de autocovarianzas para un proceso ARMA(p, q) causal, ya que en virtud de la Proposición 2.25,

$$\gamma_h = \sigma^2 \sum_{j=0}^{\infty} \psi_j \psi_{j+|h|}.$$

Teorema 2.32. Un proceso ARMA(p,q), $\{X_t\}$, cuyos polinomios $\phi(\cdot)$ y $\theta(\cdot)$ no tienen ceros comunes es invertible si y solamente si $\theta(z) \neq 0$ para todo $z \in \mathbb{C}$ tal que $|z| \leq 1$. Los coeficientes $\{\pi_j\}$ vienen dados por la relación

$$\pi(z) = \sum_{j=0}^{\infty} \pi_j z^j = \frac{\phi(z)}{\theta(z)}, \quad |z| \leq 1.$$

A continuación se proporcionan algunos resultados aplicables en contextos más generales, en los que no se suponga ni causalidad ni invertibilidad de los procesos ARMA.

Proposición 2.33. Si $\phi(\cdot)$ y $\theta(\cdot)$ no tienen ceros comunes, y $\phi(z) = 0$ para algún $z \in \mathbb{C}$ tal que $|z| = 1$, entonces no existe solución estacionaria para (2.9). Dicho de otro modo, si la ecuación (2.9) tiene solución estacionaria, entonces $\phi(z) \neq 0$ para todo $z \in \mathbb{C}$, tal que $|z| = 1$.

El siguiente teorema prueba el recíproco de la proposición anterior.

Teorema 2.34. Si $\phi(z) \neq 0$ para todo $z \in \mathbb{C}$, tal que $|z| = 1$, entonces la ecuación (2.9) tiene una solución estacionaria única, dada por

$$X_t = \sum_{j=-\infty}^{\infty} \psi_j Z_{t-j}, \tag{2.11}$$

donde ψ_j son los coeficientes determinados en (2.10).

Demostración: Si $\phi(z) \neq 0$ para todo $z \in \mathbb{C}$, tal que $|z| = 1$, entonces $\exists r > 1$ tal que $\theta(z)/\phi(z)$ es diferenciable en $\{z : r^{-1} < |z| < r\}$. Entonces, existe una sucesión $\{\psi_j\}$ tal que

$$\frac{\theta(z)}{\phi(z)} = \sum_{j=-\infty}^{\infty} \psi_j z^j = \psi(z), \quad r^{-1} < |z| < r,$$

conociéndose esta serie como serie de Laurent[2]. Del mismo modo que se demostró en el Teorema (2.30), $\sum_{j=-\infty}^{\infty} |\psi_j| < \infty$. Entonces, por la Proposición (2.25), se tiene que el proceso es estacionario.

Aplicando el operador $\phi(B)$ a cada lado de (2.11), y teniendo en cuenta que $\phi(B)\psi(B) = \theta(B)$, se tiene que $\phi(B)X_t = \theta(B)Z_t$, quedando probada la existencia, y siendo $\{X_t\}$ la solución estacionaria de las ecuaciones de los procesos ARMA.

Para probar la unicidad, sea $\{X_t\}$ una solución estacionaria cualquiera de (2.9). Como $\phi(z) \neq 0$ para todo $z \in \mathbb{C}$ tal que $|z| = 1$, por el mismo argumento que antes, se tiene que $\phi(z)^{-1} = \sum_{j=-\infty}^{\infty} \xi_j z^j = \xi(z)$ y $\sum_{j=-\infty}^{\infty} |\xi_j| < \infty$. Entonces ya se puede aplicar el operador $\xi(B)$ a cada lado de la ecuación (2.9), obteniendo

$$\xi(B)\phi(B)X_t = \xi(B)\theta(B)Z_t \iff X_t = \psi(B)Z_t.$$

[2]Resultado estudiado en la materia de Variable Compleja del Grado en Matemáticas.

Es decir, se acaba de probar que en caso de existir una solución estacionaria para la ecuación del proceso ARMA, esta coincide con (2.11). □

Observación 2.35. Los procesos AR(p) y MA(q) son un caso particular de los procesos ARMA(p, q). De hecho, un proceso AR(p) es un proceso ARMA($p, 0$), mientras que un MA(q), es un ARMA($0, q$). Consecuentemente, todas las propiedades de los procesos AR y MA se derivan de las de los ARMA:

- Los procesos AR(p) son siempre invertibles.
- Los procesos MA(q) son siempre causales y estacionarios.

2.4. Procesos no estacionarios

En esta sección se presentan un par de procesos no estacionarios que son una generalización de los procesos ARMA: los procesos ARIMA, que permiten modelar series de tiempo con tendencia; y los procesos SARIMA, que además de modelar la tendencia, también permiten modelar la estacionalidad.

2.4.1. Procesos autorregresivos integrados de medias móviles (ARIMA)

La estacionariedad en media puede fallar por la existencia de una tendencia en la serie de tiempo. Una solución que funciona en muchos casos es aplicar diferencias regulares a la serie de tiempo, es decir, calcular las diferencias entre los valores de la serie en instantes consecutivos.

Un proceso integrado de orden d es aquel que tras diferenciarlo d veces, el proceso resultante es estacionario. De este modo, los procesos autorregresivos integrados de medias móviles (ARIMA) son aquellos que tras aplicarles un número finito de diferencias regular, el resultado es un proceso ARMA.

Definición 2.36 (Proceso ARIMA(p, d, q))**.** $\{X_t\}$ es un proceso ARIMA(p, d, q) si $(1-B)^d X_t$ es un proceso ARMA(p, q), donde d es un entero no negativo que representa el número de diferencias regulares aplicadas al proceso. Equivalentemente, $\{X_t\}$ es un proceso ARIMA(p, d, q) si admite una representación del tipo

$$\phi(B)(1-B)^d X_t = c + \theta(B) Z_t,$$

donde el polinomio $\phi(B)$ no tiene raíces de módulo 1, y c es una constante real.

Una propiedad característica de los procesos integrados es que las autocorrelaciones disminuyen linealmente con el tiempo, tomando valores no nulos hasta retardos elevados. En cambio, en los procesos ARMA las autocorrelaciones decaen rápidamente.

2.4.2. Procesos ARIMA estacionales (SARIMA)

La estacionariedad en la media también puede fallar por la existencia de estacionalidad, como pasaba en la serie de la Figura 1.3 del Capítulo 1. En tal caso, la media varía de forma cíclica, i.e., $\mathbb{E}(X_t) = \mathbb{E}(X_{t-s})$, donde s es el período estacional. La estacionalidad de un proceso puede ser tratada aplicando diferencias estacionales.

A continuación se presentan los modelos SARIMA, los cuales generalizan los modelos ARIMA, ya que además de modelar la tendencia aplicando diferencias regulares, también modelan la dependencia estacional aplicando diferencias estacionales.

Definición 2.37 (Proceso SARIMA)**.** $\{X_t\}$ es un proceso SARIMA$(p, d, q)(P, D, Q)_s$ de periodo s si $Y_t := (1 - B)^d(1 - B^s)^D X_t$ es un proceso ARMA de la forma

$$\phi(B)\Phi(B_s)Y_t = c + \theta(B)\Theta(B^s)Z_t,$$

donde $\phi(z) = 1 - \phi_1 z - \ldots - \phi_p z^p$, $\Phi(z) = 1 - \Phi_1 z - \ldots - \Phi_P z^P$, $\theta(z) = 1 + \theta_1 z + \ldots + \theta_q z^q$, $\Theta(z) = 1 + \Theta_1 z + \ldots + \Theta_Q z^Q$ y c es una constante. Además, d y D son enteros no negativos, que representan el número de diferencias regulares y estacionales, respectivamente, aplicadas al proceso original.

Observación 2.38. El proceso $\{Y_t\}$ se denomina ARMA estacional, aunque puede ser reescrito como un proceso ARMA$(p + sP,\ q + sQ)$ con muchos coeficientes nulos. Esto es importante de cara a realizar la estimación y predicción de este tipo de procesos.

Observación 2.39. El proceso $\{Y_t\}$ es causal si y solamente si $\phi(z) \neq 0$ y $\Phi(z) \neq 0$.

Observación 2.40. Según [3] y [5], en la práctica normalmente basta tomar $d \leq 3$ y $D = 1$ para conseguir un transformar una serie no estacionaria (debido a la presencia de tendencia o estacionalidad) en estacionaria.

2.5. Predicción

En la bibliografía consultada se pueden distinguir dos enfoques distintos para llevar a cabo la predicción. En [3] se presenta la predicción para procesos estacionarios generales, sin suponer ninguna distribución o estructura concreta. Para ello se consideran las variables aleatorias como elementos de un espacio de Hilbert, y se busca el predictor que minimiza el error cuadrático. Para simplificar el problema, se considera el mejor predictor lineal de X_{T+h} en función de $X_1, \ldots, X_T$. El capítulo de predicción de [3] comienza presentando el mejor predictor lineal, para posteriormente introducir el algoritmo de Durbin-Levinson y el de las innovaciones, los cuales son

algoritmos recursivos que facilitan el cálculo de dicho predictor lineal en la práctica. Finalmente, se particulariza para el caso de los procesos ARMA.

En cambio, en [5] se realizan las predicciones directamente mediante esperanzas condicionadas, ya que para los procesos estudiados en este Trabajo Fin de Grado, se pueden calcular fácilmente.

Esta sección se comienza presentando cuál es el mejor predictor lineal de X_{T+h} en función de $X_1, \ldots, X_T$, tal y como se hizo en [3]. En segundo lugar, se presentará la metodología de [5] para realizar las predicciones de los procesos ARMA mediante esperanzas condicionadas.

2.5.1. Mejor predictor lineal

El mejor predictor lineal de X_{T+h} en términos de $X_T, X_{T-1}, \ldots, X_1$, $\hat{X}_T(h)$, es de la forma

$$\hat{X}_T(h) = \phi_{T1} X_T + \ldots + \phi_{TT} X_1.$$

Teniendo en cuenta que $\mathrm{Cov}(X_{T+h} - \hat{X}_T(h), X_{T+1-j}) = 0$ para todo $j \in \{1, \ldots, T\}$, se tiene que

$$\mathrm{Cov}\left(X_{T+h}, X_{T+1-j}\right) = \sum_{i=1}^{T} \phi_{Ti} \,\mathrm{Cov}\left(X_{T+1-i}, X_{T+1-j}\right) \quad \forall j \in \{1, \ldots, T\}.$$

Reescribiendo las ecuaciones de forma matricial,

$$\begin{bmatrix} \gamma_h \\ \gamma_{h+1} \\ \vdots \\ \gamma_{T+h-1} \end{bmatrix} = \begin{bmatrix} \gamma_0 & \gamma_1 & \gamma_2 & \cdots & \gamma_{T-1} \\ \gamma_1 & \gamma_0 & \gamma_1 & \cdots & \gamma_{T-2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \gamma_{T-1} & \gamma_{T-2} & \gamma_{T-3} & \cdots & \gamma_0 \end{bmatrix} \begin{bmatrix} \phi_{T1} \\ \phi_{T2} \\ \vdots \\ \phi_{TT} \end{bmatrix} \iff \Gamma_T \boldsymbol{\phi}_T = \boldsymbol{\gamma}_T(h),$$

donde $\Gamma_T = [\gamma_{i-j}]_{i,j=1}^{T}$, $\boldsymbol{\phi}_T = (\phi_1, \ldots, \phi_T)'$ y $\boldsymbol{\gamma}_T(h) := (\gamma_h, \ldots, \gamma_{T+h-1})'$. Despejando, se tiene que $\boldsymbol{\phi}_T = \Gamma_T^{-1} \boldsymbol{\gamma}_T(h)$. Cuando se dispone de una serie de tiempo de tamaño T, se puede estimar Γ_T^{-1} y $\boldsymbol{\gamma}_T$, y los coeficientes resultantes serían $\hat{\boldsymbol{\phi}}_T = \hat{\Gamma}_T^{-1} \hat{\boldsymbol{\gamma}}_T(h)$.

2.5.2. Predicción mediante esperanzas condicionadas

Se denotará por $\hat{X}_T(h)$ a la predicción de X_{T+h}, con origen en T y horizonte h, y se define su error como $e_T(h) := X_{T+h} - \hat{X}_T(h)$. Además, para determinar la bondad de la predicción es necesario escoger una función de pérdida, siendo la función de pérdida cuadrática la escogida para este trabajo. De este modo, se perseguirá minimizar el error cuadrático medio de $\hat{X}_T(h)$ dada la realización muestral $\boldsymbol{x}_T := (x_T, \ldots, x_1)$:

$$\mathrm{ECM}(\hat{X}_T(h)|\boldsymbol{x}_T) = \mathbb{E}\left[(X_{T+h} - \hat{X}_T(h))^2 | \boldsymbol{x}_T\right] = \mathbb{E}\left[e_T^2(h)|\boldsymbol{x}_T\right]. \tag{2.12}$$

Proposición 2.41. El predictor que minimiza el error cuadrático medio (2.12) es la esperanza de X_{T+h} condicionada a la información disponible $x_1, \ldots, x_T$.

Demostración. Restando y sumando $\mathbb{E}[X_{T+h}|\boldsymbol{x}_T]$, y desarrollando el cuadrado se tiene que

$$\begin{aligned}\mathrm{ECM}(\hat{X}_T(h)|\boldsymbol{x}_T) &= \mathbb{E}\left[\left(X_{T+h} - \mathbb{E}[X_{T+h}|\boldsymbol{x}_T] + \mathbb{E}[X_{T+h}|\boldsymbol{x}_T] - \hat{X}_T(h)\right)^2 |\boldsymbol{x}_T\right] \\ &= \mathbb{E}\left[(X_{T+h} - \mathbb{E}[X_{T+h}|\boldsymbol{x}_T])^2 |\boldsymbol{x}_T\right] + \mathbb{E}\left[(\mathbb{E}[X_{T+h}|\boldsymbol{x}_T] - \hat{X}_T(h))^2|\boldsymbol{x}_T\right] \\ &\quad + 2\mathbb{E}\left[(X_{T+h} - \mathbb{E}[X_{T+h}|\boldsymbol{x}_T])(\mathbb{E}[X_{T+h}|\boldsymbol{x}_T] - \hat{X}_T(h))|\boldsymbol{x}_T\right]. \qquad (2.13)\end{aligned}$$

Con respecto al tercer sumando, $(\mathbb{E}[X_{T+h}|\boldsymbol{x}_T] - \hat{X}_T(h))$ puede salir fuera de la esperanza por ser $\mathbb{E}[X_{T+h}|\boldsymbol{x}_T]$ y $\hat{X}_{T+h}$ constantes. Teniendo en cuenta además, que $\mathbb{E}\left[X_{T+h}|\boldsymbol{x}_T\right] = \mathbb{E}\left[\mathbb{E}[X_{T+h}|\boldsymbol{x}_T]|\boldsymbol{x}_T\right]$, se puede concluir que el tercer sumando se anula. Por otra parte, como el primer sumando de la expresión anterior es igual a $\mathrm{Var}(X_{T+h}|\boldsymbol{x}_T)$, se puede rescribir la expresión (2.13) como

$$\mathrm{ECM}(\hat{X}_T(h)|\boldsymbol{x}_T) = \mathrm{Var}(X_{T+h}|\boldsymbol{x}_T) + \mathbb{E}\left[(\mathbb{E}[X_{T+h}|\boldsymbol{x}_T] - \hat{X}_T(h))^2|\boldsymbol{x}_T\right].$$

El primer término de la expresión anterior no depende del predictor $(\hat{X}_T(h))$, por lo que se buscará minimizar el error cuadrático medio de predicción. Para ello basta minimizar el segundo término, y se obtiene que

$$\hat{X}_T(h) = \mathbb{E}[X_{T+h}|\boldsymbol{x}_T]. \qquad \square$$

Observación 2.42. Se ha demostrado cuál es el predictor óptimo para una serie de tiempo concreta. En el apéndice 8.1 de [5] se demuestra que la esperanza condicionada sigue siendo el predictor óptimo cuando además de considerar la serie de tiempo observada, también se considera cualquier realización muestral posible.

Teniendo en cuenta el resultado anterior, tiene sentido plantear la tarea de predicción de un proceso ARIMA usando esperanzas condicionadas. Se definen los siguientes predictores:

$$\hat{X}_T(h) := \mathbb{E}[X_{T+h}|\boldsymbol{x}_T] \quad \text{y} \quad \hat{Z}_T(h) := \mathbb{E}[Z_{T+h}|\boldsymbol{x}_T], \quad \forall h \in \{1, 2, \ldots\}$$

donde $\boldsymbol{Z}_T := (Z_T, \ldots, Z_1)$.

Sea $\{x_1, \ldots, x_T\}$ una realización muestral de tamaño T de un un proceso ARIMA(p, d, q), $\{X_t\}$, cuya ecuación es $\phi(B)(1-B)^d X_t = c + \theta(B)Z_t$. Definiendo un nuevo operador $\varphi(B) := \phi(B)(1-B)^d$ (cuyo orden será $k := p + d$), la ecuación puede ser reescrita como $\varphi(B)X_t = c + \theta(B)Z_t$. Desarrollando los términos de la ecuación se obtiene que

$$X_{T+h} = c + \varphi_1 X_{T+h-1} + \ldots + \varphi_h X_{T+h-k} + Z_{T+h} + \theta_1 Z_{T+h-1} + \ldots + \theta_q Z_{T+h-q}.$$

Tomando esperanzas condicionadas a la información disponible $(\boldsymbol{x}_T := x_T, \ldots, x_1)$, se tiene que:

$$\hat{X}_T(h) = \mathbb{E}[X_{T+h} \mid \boldsymbol{x}_T] = c + \sum_{i=1}^{p} \varphi_i \, \hat{X}_T(h-i) + \sum_{j=1}^{q} \theta_j \, \hat{Z}_T(h-j). \qquad (2.14)$$

Si $h-i>0$, la expresión $\hat{X}_T(h-i)$ es la esperanza condicionada de algo que no se ha observado todavía, mientras que cuando $h-i \leq 0$ sí, por lo que la esperanza coincidirá con el valor observado. Con respecto a las innovaciones, si $h-j>0$, la esperanza de innovaciones futuras condicionadas a valores pasados de la serie es nula, ya que las observaciones de ruido blanco están incorreladas. Asimismo, cuando $h-j \leq 0$ las esperanzas son conocidas, ya que Z_{T+h-j} se puede calcular recursivamente.

Otra conclusión que se puede sacar a la vista de la expresión (2.14) es que si $h>q$ los términos de media móvil serían nulos, y la predicción pasaría a ser expresada únicamente a partir de los términos autorregresivos del modelo.

A continuación se mustran algunos ejemplos que ilustran de manera práctica cómo se realizar la tarea de predicción.

Ejemplo 2.43 (Predicción para un proceso AR(1) de media nula)**.** La ecuación de dicho proceso es $X_t = \phi X_{t-1} + Z_t$. Las predicciones para los primeros cuatro horizontes temporales son:

$$\hat{X}_T(1) = \phi x_T \qquad \hat{X}_T(2) = \phi \hat{X}_T(1) = \phi^2 x_T$$
$$\hat{X}_T(3) = \phi \hat{X}_T(2) = \phi^3 x_T \qquad \hat{X}_T(4) = \phi \hat{X}_T(3) = \phi^4 x_T.$$

Como $\phi^T \to 0$ cuando $T \to \infty$, la predicción a la larga converge a la media del proceso, que en este caso es 0.

Ejemplo 2.44 (Predicción para un proceso MA(1) de media nula)**.** La ecuación de dicho proceso es $X_t = Z_t + \theta Z_{t-1}$. Las predicciones para los dos primeros horizontes temporales son:

$$\hat{X}_T(1) = \mathbb{E}[X_{T+1} \mid \boldsymbol{x}_T] = \mathbb{E}[Z_{T+1} + \theta Z_T \mid \boldsymbol{x}_T] = \theta z_T$$
$$\hat{X}_T(2) = \mathbb{E}[X_{T+2} \mid \boldsymbol{x}_T] = \mathbb{E}[Z_{T+2} + \theta Z_{T+1} \mid \boldsymbol{x}_T] = \mathbb{E}[Z_{T+2} + \theta X_{T+1} - \theta^2 Z_T \mid \boldsymbol{x}_T] = 0.$$

Se puede concluir que para todo horizonte $h>1$, la predicción es la media del proceso, que en este caso es cero.

Ejemplo 2.45 (Predicción para un proceso ARIMA(0,1,0))**.** La ecuación de dicho proceso es $X_t = X_{t-1} + Z_t$. La predicción para un horizontal temporal h es: $\hat{X}_T(h) = x_T$. Es decir, el predictor óptimo para un paseo aleatorio es el último valor observado de la serie.

Ejemplo 2.46 (Predicción para un proceso ARIMA(2,1,3))**.** La ecuación de dicho proceso sería

$$(1-\phi_1 B - \phi_2 B^2)(1-B)X_t = (1+\theta_1 B + \theta_2 B^2 + \theta_3 B^3)Z_t,$$

equivalentemente,

$$X_t = (1+\phi_1)X_{t-1} + (\phi_1+\phi_2)X_{t-2} + \phi_2 X_{t-3} + Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2} + \theta_3 Z_{t-3}.$$

Aplicando esperanzas condicionadas para realizar la predicción a horizonte 1, se tiene que:

$$\begin{aligned}\hat{X}_T(1) &= (1+\phi_1)X_T - (\phi_1+\phi_2)X_{T-1} + \phi_2 X_{T-2} + \hat{Z}_T(1) + \theta_1 Z_T + \theta_2 Z_{T-1} + \theta_3 Z_{T-2} \\ &= (1+\phi_1)X_T - (\phi_1+\phi_2)X_{T-1} + \phi_2 X_{T-2} + \theta_1 Z_T + \theta_2 Z_{T-1} + \theta_3 Z_{T-2}\end{aligned}$$

donde Z_t, Z_{T-1}, Z_{T-2} son conocidos (calculables como residuos del modelo ajustado), y $\hat{Z}_T(1) = \mathbb{E}[Z_{T+1}|\boldsymbol{x}_T] = 0$.

Para realizar la predicción a horizonte 2, es necesario utilizar la predicción anterior, y tener en cuenta que $\hat{Z}_T(2) = \hat{Z}_T(1) = 0$:

$$\begin{aligned}\hat{X}_T(2) &= (1+\phi_1)\hat{X}_T(1) - (\phi_1+\phi_2)X_T + \phi_2 X_{T-1} + \hat{Z}_T(2) + \theta_1 \hat{Z}_T(1) + \theta_2 Z_T + \theta_3 Z_{T-1} \\ &= (1+\phi_1)\hat{X}_T(1) - (\phi_1+\phi_2)X_T + \phi_2 X_{T-1} + \theta_2 Z_T + \theta_3 Z_{T-1}.\end{aligned}$$

Para horizonte 3, se tiene que $\hat{Z}_T(3) = \hat{Z}_T(2) = \hat{Z}_T(1) = 0$, por lo que:

$$\hat{X}_T(3) = (1+\phi_1)\hat{X}_T(2) - (\phi_1+\phi_2)\hat{X}_T(1) + \phi_2 X_T + \theta_3 Z_T$$

Finalmente, para horizonte 4, se anulan todas las innovaciones para todo $j \in \{1,2,3\}$:

$$\hat{X}_T(4) = (1+\phi_1)\hat{X}_T(3) - (\phi_1+\phi_2)\hat{X}_T(2) + \phi_2 \hat{X}_T(1)$$

Se observa que a partir de $h > 3$, las innovaciones dejan de aportar información al predictor, y la predicción se realiza únicamente con base en las predicciones anteriores.

En la sección 8.3 de [5] se ofrece una interpretación de las predicciones basada en resultados de ecuaciones en diferencias finitas. Según esta interpretación, la predicción puede descomponerse en varias componentes: una que refleja la tendencia esperada del proceso a largo plazo y que puede expresarse mediante un polinomio, otra de carácter transitorio que representa el comportamiento a corto plazo y cuya influencia disminuye a medida que se amplía el horizonte de predicción, y una tercera componente estacional que aparece únicamente en modelos que incorporan dicha estructura.

2.5.3. Varianza de las predicciones

Si $\{X_t\}$ es un proceso causal, este puede escribirse como $X_t = \sum_{j=0}^{\infty} \psi_j Z_{t-j}$. Entonces,

$$X_{T+h} = \sum_{j=0}^{\infty} \psi_j Z_{T+h-j} \quad \text{y} \quad \hat{X}_T(h) = \sum_{j=0}^{\infty} \psi_{h+j} Z_{T-j}.$$

El error de predicción se obtiene restando los dos términos anteriores:

$$X_{T+h} - \hat{X}_T(h) = \sum_{j=0}^{\infty} \psi_{j+h} Z_{T-j} = \psi_0 Z_{T+h} + \psi_1 Z_{T+h-1} + \ldots + \psi_{h-1} Z_{T+1}.$$

La varianza de la predicción es

$$\mathrm{Var}(X_{T+h} - \hat{X}_T(h)|\boldsymbol{x}_T) = \sigma^2(\psi_0^2 + \psi_1^2 + \ldots + \psi_{h-1}^2).$$

La incertidumbre es creciente con respecto al horizonte temporal h. Además, en un proceso estacionario $\sum_{j=0}^{\infty} |\psi_j|$ es convergente, por lo que la varianza de predicción converge a un valor constante al aumentar h. En cambio, en procesos no estacionarios, la serie $\sum_{j=0}^{\infty} \psi_j^2$ no es convergente, por lo que la incertidumbre de predicción crece sin límite.

Por otra parte, si se supone que las innovaciones son gausianas, X_{T+h} seguirá una distribución normal de media $\hat{X}_T(h)$ y varianza $\sigma^2(\psi_0^2 + \psi_1^2 + \ldots + \psi_{h-1}^2)$. Entonces, se puede construir un intervalo de predicción para X_{T+h} con un nivel de significación $(1-\alpha)\,\%$ como sigue:

$$\left(\hat{X}_T(h) \pm z_{\alpha/2}\sqrt{\sigma^2(\psi_0^2 + \psi_1^2 + \ldots + \psi_{h-1}^2)}\right). \tag{2.15}$$

2.5.4. Consideraciones sobre la predicción en la práctica

El intervalo de confianza anteriormente propuesto para las predicciones usa los parámetros reales del modelo, además de suponer la normalidad de las innovaciones. No obstante, en la práctica solo se dispone de estimaciones de dichos parámetros, y es posible que las innovaciones no sean guassianas. En general, se puede decir que existen cuatro fuentes de incertidumbre a la hora de realizar la predicción:

1. Innovaciones futuras. Este tipo de incertidumbre no depende del tamaño muestral, y es inevitable. De hecho, en (2.15) se vio que esta incertidumbre crece a medida que aumenta el horizonte de predicción.

2. La distribución de las innovaciones. Se puede disminuir esta incertidumbre aumentando el tamaño muestral, ya que a medida que este aumenta, los contrastes ganan potencia.

3. Los valores reales de los parámetros. A medida que aumenta el tamaño muestral, las estimaciones se vuelven más precisas.

4. El modelo que ha generado los datos. Esta incertidumbre también se puede disminuir aumentando el tamaño muestral.

Por una parte, en situaciones en las que el tamaño muestral sea elevado y se pueda aceptar la normalidad de las innovaciones, se puede sustituir en (2.15) por las estimaciones de los parámetros para obtener el intervalo de predicción.

Por otra parte, en situaciones en las que las innovaciones no son gaussianas, o el tamaño muestral no es suficientemente elevado y no se quiera obviar el tercer tipo de incertidumbre, se pueden

calcular los intervalos de predicción con horizonte h mediante remuestreo *bootstrap*, tal y como se muestra en [3]. Se detallan a continuación los pasos a seguir:

1. Realizar la estimación del modelo, para obtener $\hat{\boldsymbol{\beta}}$, y poder calcular los residuos, i.e., la estimación de las innovaciones, $\hat{z}_t$.

2. Simular B valores futuros (predicciones) de la serie con origen T y horizonte h, obteniendo los siguientes valores:

$$\left\{\hat{X}_T^{(1)}(1), \ldots, \hat{X}_T^{(1)}(h)\right\}, \ldots, \left\{\hat{X}_T^{(B)}(1), \ldots, \hat{X}_T^{(B)}(h)\right\}.$$

3. Los extremos del intervalo de predicción para el horizonte h para un nivel de significación $(1-\alpha)\,\%$ son los cuantiles $\alpha/2$ y $1-\alpha/2$ de los valores $\left\{x_T^{(i)}(h)\right\}_{i=1}^{B}$.

Para simular un valor futuro $\{x_T^{(i)}(1), \ldots, x_T^{(i)}(h)\}, i \in \{1, \ldots, B\}$ se siguen los siguientes pasos:

1. Se obtiene una muestra con reemplazamiento de los residuos $\{z_1, \ldots, z_T\}$. Sea $z_1^*, \ldots, z_T^*$ dicha muestra.

2. Se reconstruye una nueva serie usando $\hat{\boldsymbol{\beta}}$ y $z_1^*, \ldots, z_T^*$ como sigue:

$$x_k^* = \hat{\phi}_1 x_{k-1}^* + \ldots + \hat{\phi}_p x_{k-p}^* + z_t^* + \hat{\theta}_1 z_{k-1}^* + \ldots + \hat{\theta}_q z_{k-q}^*.$$

3. Se estiman los parámetros del modelo para la serie $\{x_k^*\}_{k=1}^T$, dando lugar a $\hat{\boldsymbol{\phi}}^*$ y $\hat{\boldsymbol{\theta}}^*$.

4. Se calculan las predicciones de la serie original $\{x_k\}_{k=1}^T$ usando $\hat{\boldsymbol{\phi}}^*$, $\hat{\boldsymbol{\theta}}^*$, y las residuos originales $\{z_1, \ldots, z_T\}$, obteniendo $\{x_T^{(i)}(1), \ldots, x_T^{(i)}(h)\}$.

2.6. Estimación de procesos ARMA

Dada una serie de tiempo estacionaria de media nula $\{x_t\}$, es necesario estimar los parámetros $\boldsymbol{\phi} = (\phi_1, \ldots, \phi_p)$, $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_q)$ y σ^2. En esta sección se presentan dos métodos para llevar a cabo la estimación.

Observación 2.47. Para esta sección se ha supuesto sin pérdida de generalidad que la serie de tiempo tiene media nula. En caso de que no sea así, tal y como se propone en [3], se calcularía la media muestral $\hat{\mu}$ y la serie resultante $\{x_t - \hat{\mu}\}$ se usaría para la estimación de los parámetros. Otra opción para estimar la media, propuesta en [5], sería incluir la constante c en el modelo ARMA, y realizar la estimación de este parámetro junto con los otros parámetros del modelo. En este en este Trabajo, por simplicidad, se ha obtado por la primera opción.

2.6.1. Estimación de Yule-Walker para procesos autorregresivos

A continuación se describe un método de estimación para procesos autorregresivos causales, basado en momentos y en las ecuaciones de Yule-Walker, siguiendo [3]. Sea $\{X_t\}$ un proceso autorregresivo causal de orden p y de media nula,

$$X_t - \phi_1 X_{t-1} - \ldots - \phi_p X_{t-p} = Z_t. \tag{2.16}$$

Por ser causal, el proceso $\{X_t\}$ se puede reescribir como

$$X_t = \sum_{j=0}^{\infty} \psi_j Z_{t-j}. \tag{2.17}$$

Multiplicando cada lado de (2.16) por X_{t-j}, $j \in \{0, \ldots, p\}$, tomando esperanzas, y usando (2.17) en el lado derecho de la igualdad, se obtienen las ecuaciones de Yule-Walker,

$$\begin{cases} \mathbb{E}(X_t X_t) - \phi_1 \mathbb{E}(X_{t-1} X_t) - \ldots - \phi_p \mathbb{E}(X_{t-p} X_t) = \mathbb{E}(Z_t X_t) = \sum_{j=0}^{\infty} \psi_j \mathbb{E}\left(Z_t Z_{t-j}\right) \\ \mathbb{E}(X_t X_{t-1}) - \phi_1 \mathbb{E}(X_{t-1} X_{t-1}) - \ldots - \phi_p \mathbb{E}(X_{t-p} X_{t-1}) = \mathbb{E}(Z_t X_{t-1}) = \sum_{j=0}^{\infty} \psi_j \mathbb{E}\left(Z_t Z_{t-1-j}\right) \\ \vdots \\ \mathbb{E}(X_t X_{t-p}) - \phi_1 \mathbb{E}(X_{t-1} X_{t-p}) - \ldots - \phi_p \mathbb{E}(X_{t-p} X_{t-p}) = \mathbb{E}(Z_t X_{t-p}) = \sum_{j=0}^{\infty} \psi_j \mathbb{E}\left(Z_t Z_{t-p-j}\right). \end{cases}$$

Teniendo en cuenta que los procesos $\{X_t\}$ y $\{Z_t\}$ tienen media nula, y que para $j \in \{0, \ldots, p\}$, $\mathbb{E}(X_t X_{t-j}) = \gamma_j$, $\mathbb{E}\left(Z_t Z_{t-j}\right) = \sigma^2$ si $j = 0$, y 0 en otro caso, se pueden rescribir las ecuaciones anteriores de forma más compacta como

$$\sigma^2 = \gamma_0 - \sum_{i=1}^{p} \phi_i \gamma_i = \gamma_0 - \boldsymbol{\phi}' \boldsymbol{\gamma}_p, \tag{2.18}$$

y

$$\Gamma_p \boldsymbol{\phi}_p = \boldsymbol{\gamma}_p, \tag{2.19}$$

donde Γ_p es la matriz de covarianzas $[\gamma_{i-j}]_{i,j=1}^{p}$, $\boldsymbol{\phi}_p = (\phi_1, \ldots, \phi_p)'$ y $\boldsymbol{\gamma}_p = (\gamma_1, \ldots, \gamma_p)'$.

Reemplazando en (2.18) y (2.19) cada término por su respectiva versión muestral, y teniendo en cuenta que si $\hat{\gamma}_0 > 0$, entonces $\hat{\Gamma}_p$ es no singular, los estimadores de Yule-Walker $\hat{\boldsymbol{\phi}}$ y $\hat{\sigma}^2$ son:

$$\hat{\sigma}^2 = \hat{\gamma}(0) - \hat{\boldsymbol{\phi}}' \hat{\boldsymbol{\gamma}}_p, \quad \text{y} \quad \hat{\boldsymbol{\phi}}_p = \hat{\Gamma}_p^{-1} \hat{\boldsymbol{\gamma}}_p.$$

Observación 2.48. A pesar de que en muchos casos los estimador obtenidos por el método de los momentos son poco eficientes (por ejemplo, para un MA(1)), para el caso de los modelos autorregresivos no sucede lo mismo. De hecho, el estimador de Yule-Walker $\hat{\boldsymbol{\phi}}$ tiene la misma distribución asintótica que el obtenido por máxima verosimilitud [3].

Observación 2.49. Se puede demostrar que $\hat{\boldsymbol{\phi}}_p$ cumple que $1 - \hat{\phi}_1 z \ldots - \hat{\phi}_p z^p \neq 0$ para todo $|z| \leq 1$. Por lo tanto, el modelo ajustado $X_t - \hat{\phi}_1 X_{t-1} \ldots - \hat{\phi}_p X_{t-p} = Z_t$ es causal.

2.6.2. Estimación por máxima verosimilitud

Otra forma de estimar los parámetros del modelo es mediante el método de máxima verosimilitud[3], que consiste en encontrar los valores de dichos parámetros que maximizan la probabilidad de observar la serie observada bajo el supuesto del modelo. A continuación se proponen dos enfoques equivalentes para construir la función de verosimilitud de un proceso ARMA(p,q) gaussiano de media nula. El primero de ellos es el más general, pero su aplicación no es directa, ya que necesita invertir una matriz. El segundo de ellos, construye una función de verosimilitud que evita este problema, pero aún así, sigue sin poder usarse directamente en la práctica.

Construcción 1: Mediante la función de densidad conjunta.

Sea $\{X_t\}$ es un proceso ARMA(p,q) gaussiano de media nula. Sea $\boldsymbol{x}_T := \{x_1, \ldots, x_T\}$ una muestra de $\mathbf{X}_T = (X_1, \ldots, X_T)'$. Se denota por Γ_T a la matriz de covarianzas del vector aleatorio $\mathbf{X}_T$, $\Gamma_T = \mathbb{E}[\mathbf{X}_T\mathbf{X}_T']$. Las funciones de verosimilitud y log-verosimilitud para dicha muestra son, respectivamente,

$$L(\Gamma_T) = (2\pi)^{-T/2}(\det \Gamma_T)^{-1/2} \exp\left\{-\frac{1}{2}\mathbf{x}_T'\Gamma_T^{-1}\mathbf{x}_T\right\} \tag{2.20}$$

y

$$\ell(\Gamma_T) = -\frac{T}{2}\log(2\pi) - \frac{1}{2}\log(\det \Gamma_T) - \frac{1}{2}\mathbf{x}_T'\Gamma_T^{-1}\mathbf{x}_T, \tag{2.21}$$

donde Γ_T depende de $\phi_1, \ldots, \phi_p, \theta_1, \ldots, \theta_q$ y σ.

Observación 2.50. En caso de que el proceso no sea gaussiano, en [3] se sigue considerando esta función de verosimilitud como una buena medida de la bondad de ajuste de los parámetros a los datos.

Cuando el tamaño muestral es relativamente grande, invertir Γ_T puede ser un problema. A continuación se construirá otra expresión de la función de verosimilitud, la cual evitará tener que invertir matrices.

Construcción 2: Mediante distribuciones univariantes.

Por las propiedades de la densidad condicional, se puede reescribir la función de densidad conjunta como producto de T distribuciones univariantes:

$$f(x_1, \ldots, x_T) = f(x_1)f(x_2|x_1)f(x_3|x_2, x_1), \ldots f(x_T|x_{T-1}, \ldots, x_1). \tag{2.22}$$

Al haber supuesto que $\mathbf{X}_T$ es normal, las distribuciones condicionadas serán normales. Tal y como se vio en la sección de predicción $\mathbb{E}(X_t|x_{t-1}, \ldots, x_1) = \hat{X}_{t-1}(1) =: \hat{x}_t \, \forall t \geq 2$, mientras que

[3] Método explorado en la asignatura de Inferencia Estadística del Grado en Matemáticas.

$\hat{x}_1 := \mathbb{E}(X_1)$. Por otra parte, $v_t := \mathrm{Var}(X_t|x_{t-1},\ldots,x_1)\,\forall t \geq 2$, y $v_1 := \mathrm{Var}(X_1)$. De este modo, la función de densidad conjunta de la muestra en cuestión es

$$f(x_1,\ldots,x_T) = \prod_{t=1}^{T}(2\pi)^{-1/2}\, v_t^{-1/2} \exp\left\{\frac{(x_t-\hat{x}_t)^2}{v_t}\right\}.$$

Tomando logaritmos, la función de log-verosimilitud resultante es:

$$\ell(\phi_1,\ldots,\phi_p,\theta_1,\ldots,\theta_q,\sigma) = -\frac{T}{2}\log(2\pi) - \frac{1}{2}\sum_{t=1}^{T}\log v_t - \frac{1}{2}\sum_{t=1}^{T}\frac{(x_t-\hat{x}_t)^2}{v_t}. \tag{2.23}$$

Suponiendo que $\{X_t\}$ es un proceso causal, este puede ser reescrito como $X_t = \sum_{j=0}^{\infty}\psi_j Z_{t-j}$, y la varianza v_t se puede descomponer en dos factores: $v_t = \sigma^2 r_t$ donde r_t no depende de σ^2. Entonces,

$$\ell(\phi_1,\ldots,\phi_p,\theta_1,\ldots,\theta_q,\sigma) = -\frac{T}{2}\log(2\pi) - \frac{T}{2}\log\sigma^2 - \frac{1}{2}\sum_{t=1}^{T}\log r_t - \frac{1}{2\sigma^2}\sum_{t=1}^{T}\frac{(x_t-\hat{x}_t)^2}{r_t}. \tag{2.24}$$

A continuación se muestran varios ejemplos que evidenciarán que (2.24) no se puede aplicar de forma directa en la práctica, y se propondrá una alternativa para mitigar este problema.

Ejemplo 2.51 (AR(1))**.** La ecuación de este proceso es $X_t = \phi X_{t-1} + Z_t$. Se construirá la función de verosimilitud exacta empleado las distribuciones condicionadas, según (2.22).

Por una parte, $\mathbb{E}(X_1) = 0$ y $\mathrm{Var}(X_1) = E(X_1^2) = \frac{\sigma^2}{1-\phi^2}$. Por otra parte, si $t > 1$, $\hat{x}_t = \mathbb{E}(X_t|x_{t-1},\ldots,x_1) = \phi x_{t-1}$, y $v_t = \mathrm{Var}(x_t|x_{t-1},\ldots,x_1) = \sigma^2$, por lo que $r_t = 1$. Suponiendo normalidad conjunta, las distribuciones condicionadas son normales también, por lo que la función de verosimilitud resultante cumple que:

$$\ell(\phi,\sigma^2) \propto -\frac{T}{2}\log\sigma^2 + \frac{1}{2}\log(1-\phi^2) - \frac{(1-\phi^2)x_1^2}{2\sigma^2} - \frac{1}{2\sigma^2}\sum_{t=2}^{T}(x_t-\phi x_{t-1})^2$$

Conviene observar que el segundo y tercer término de la expresión anterior han aparecido al tener en cuenta la primera observación de la muestra, x_1. No obstante, esto ha provocado que ahora sea necesario hallar los ceros de una ecuación cúbica. Para evitar esta situación, se podría estimar el parámetro respecto de la verosimilitud condicionada a x_1, definida a continuación:

$$\ell(\phi,\sigma|x_1) \propto -\frac{T-1}{2}\log\sigma^2 - \frac{1}{2\sigma^2}\sum_{t=2}^{T}(x_t-\phi x_{t-1})^2.$$

Entonces, para obtener el valor de ϕ que maximice esta log-verosimilitud condicional basta minimizar una suma de cuadrados, cuyos términos son lineales. Es decir, condicionando a la primera observación de la serie, máxima verosimilitud condicionada equivale a mínimos cuadrados. Por otra parte, la diferencia entre las estimaciones por verosimilitud exacta y condicionada es menor cuanto mayor sea el tamaño muestral.

Ejemplo 2.52 (AR(p)). En este caso, solo se conocen las distribuciones condicionadas univariantes de (2.22) para $t \in \{p+1, \ldots, T\}$, por lo que la función de la muestra resultante es

$$f(x_1, \ldots, x_T) = f(x_1, \ldots, x_p) f(x_{p+1}|x_p, \ldots, x_1) \ldots f(x_T|x_{T-1}, \ldots, x_1).$$

El primer factor es una densidad multivariante, como la de (2.20). Como esto hace menos directa la tarea de maximización, se propone realizar la estimación respecto de la función de verosimilitud condicionada a las p primeras observaciones de la serie:

$$L(\phi, \sigma|x_1, \ldots, x_p) = -\frac{T-p}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{t=p+1}^{T} \left(x_t - \sum_{j=1}^{p} \phi_j x_{t-j} \right)^2.$$

Una vez más, la maximización de la verosimilitud condicional equivale a mínimos cuadrados. □

El siguiente ejemplo pretende ilustrar que la estimación de modelos con medias móviles es también compleja, ya que la función de verosimilitud exacta es no lineal con respecto a los parámetros a optimizar.

Ejemplo 2.53 (MA(1)). La ecuación asociada a este proceso es: $X_t = Z_t + \theta Z_{t-1}$, la cual puede ser reescrita como:

$$X_t = Z_t + (-1)^0 \theta X_{t-1} + (-1)^1 \theta^2 X_{t-2} + \ldots + (-1)^{t-2} \theta^{t-1} X_1.$$

Entonces, $\hat{x}_t = \mathbb{E}(X_t|x_{T-1}, \ldots, x_1) = (-1)^0 \theta x_{t-1} + (-1)^1 \theta^2 x_{t-2} + \ldots + (-1)^{t-2} \theta^{t-1} x_1$. El inconveniente evidente de esta expresión es que tienen términos no lineales con respecto a θ, lo que complica la maximización de la función de verosimilitud. No obstante, al igual que antes, si se condiciona a que $Z_1 = 0$,

$$\mathbb{E}(X_t|x_{t-1}, \ldots, x_1, z_1) = \theta z_{t-1} \quad \text{y} \quad v_t = \mathrm{Var}(X_t|x_{t-1}, \ldots, x_1, z_1) = \sigma^2.$$

Entonces, la función de verosimilitud condicional da lugar a un problema de optimización más sencillo:

$$L(\theta|x_1, z_1) = -\frac{T-1}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{t=2}^{T} (x_t - \theta z_{t-1})^2.$$

Observación 2.54. A la vista de los ejemplos revisados hasta ahora, parece que no es fácil calcular la verosimilitud exacta, y que solo es viable calcular la verosimilitud condicionada. Esto se debe a que las predicciones $\hat{x}_t$ se han calculado mediante la media condicionada, y llega un momento en el que no se puede calcular la media condicionada de un valor que depende de valores anteriores a x_1. Por lo tanto, solo será factible calcular la verosimilitud condicionada. No obstante, si en vez de calcular $\hat{x}_t$ mediante esperanzas condicionadas, se calculase mediante el algoritmo de las innovaciones [2, 3], la verosimilitud obtenida sería la exacta. Además, este algoritmo calcula $\hat{x}_t$ de forma eficiente computacionalmente hablando.

Relación entre las dos construcciones de la función de verosimilitud.

La función de verosimilitud (2.23) es un caso particular de (2.21), tal y como se prueba a continuación. En [3] se demuestra que existe una matriz C triangular inferior y con unos en la diagonal, de dimensión $T \times T$, tal que

$$\hat{\boldsymbol{x}}_T = (C - I)(\boldsymbol{x}_T - \hat{\boldsymbol{x}}_T),$$

donde $\hat{\boldsymbol{x}}_T := (\hat{x}_1, \ldots, \hat{x}_T)$ e I es la matriz identidad de orden T. Entonces $\boldsymbol{x}_T = \boldsymbol{x}_T - \hat{\boldsymbol{x}}_T + \hat{\boldsymbol{x}}_T = C(\boldsymbol{x}_T - \hat{\boldsymbol{x}}_T)$. Teniendo en cuenta que la matriz de covarianzas de $(\boldsymbol{x}_T - \hat{\boldsymbol{x}}_T)$ es $D = \operatorname{diag}(v_1, \ldots, v_T)$, se sigue que $\Gamma_T = CDC'$. Por lo tanto,

$$\mathbf{x}_T' \Gamma_T^{-1} \mathbf{x}_T = (\boldsymbol{x}_T - \hat{\boldsymbol{x}}_T)' D^{-1} (\boldsymbol{x}_T - \hat{\boldsymbol{x}}_T) = \sum_{t=1}^{T} \frac{(x_t - \hat{x}_t)^2}{v_{t-1}}$$

y

$$\det \Gamma_T = (\det C)^2 (\det D) = (\det D) = v_1 \ldots v_T.$$

Observación 2.55. Los elementos de la matriz C vienen dados por el algoritmo de las innovaciones. Véase [3] para más detalles.

Propiedades de los estimadores de máxima verosimilitud

Al haber estimado los parámetros por máxima verosimilitud, bajo ciertas condiciones generales de regularidad, se tendrá que las estimaciones serán consistentes, asintóticamente normales, y asintóticamente eficientes. Denotando por $\hat{\boldsymbol{\beta}} = (\hat{\phi}_1, \ldots, \hat{\phi}_p, \hat{\theta}_1, \ldots, \hat{\theta}_q)'$, se tendrá que

$$\sqrt{T}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} N\left(0, \Sigma(\boldsymbol{\beta})\right),$$

donde $\Sigma(\boldsymbol{\beta})$ es la matriz de convarianzas asintótica. Para $p, q \geq 1$ esta matriz es

$$\Sigma(\boldsymbol{\beta}) = \sigma^2 \begin{bmatrix} \mathbb{E}(U_t U_t') & \mathbb{E}(U_t V_t') \\ \mathbb{E}(V_t U_t') & \mathbb{E}(V_t V_t') \end{bmatrix}^{-1}, \tag{2.25}$$

donde $U_t = (U_t, \ldots, U_{t+1-p})'$, $V_t = (V_t, \ldots, V_{t+1-q})'$ y $\{U_t\}, \{V_t\}$ son los procesos autorregresivos, $\phi(B)U_t = Z_t$ y $\theta(B)V_t = Z_t$ respectivamente. Por otra parte, para $p = 0$, $\Sigma(\beta) = \sigma^2[\mathbb{E}(V_t V_t')]^{-1}$, y para $q = 0$, $\Sigma(\beta) = \sigma^2[\mathbb{E}(U_t U_t')]^{-1}$.)

A continuación se muestran algunos ejemplos tomados de [3], donde se calculan las distribuciones asintóticas para algunos de los procesos descritos anteriormente.

Ejemplo 2.56 (AR(p))**.** A la vista de (2.25), se tiene que $\Sigma(\boldsymbol{\beta}) = \sigma^2[\mathbb{E}(U_t U_t')]^{-1} = \sigma^2 \Gamma_p^{-1}$, donde $\phi(B)U_t = Z_t$ y $\Gamma_p = \mathbb{E}(U_t' U_t) = [\mathbb{E}(X_i X_j)]_{i,j=1}^{p}$. Por lo tanto,

$$\hat{\boldsymbol{\phi}} \xrightarrow{d} N\left(\boldsymbol{\phi}, \frac{\sigma^2 \Gamma_p^{-1}}{T}\right).$$

Ejemplo 2.57 (AR(1))**.** Como $p = 1$, se tiene que

$$\Gamma_1 = \gamma_0 = \mathrm{Cov}(X_t, X_t) = \mathrm{Var}(X_t) = \mathrm{Var}(\phi X_{t-1} + Z_t) = \phi\,\mathrm{Var}(X_t) + \sigma^2 \implies \gamma_0 = \frac{\sigma^2}{1-\phi^2}.$$

Por lo tanto,

$$\hat{\phi} \xrightarrow{d} N\left(\phi, \frac{1-\phi^2}{T}\right).$$

Es decir, la varianza de la estimación será menor cuanto mayor sea el tamaño muestral y cuanto más próximo sea el parámetro ϕ a 1.

Ejemplo 2.58 (MA(q))**.** A la vista de (2.25), se tiene que $V(\boldsymbol{\theta}) = \sigma^2[\mathbb{E}(V_t V_t')]^{-1} = \sigma^2\Gamma_q^{-1}$, donde $\theta(B)V_t = Z_t$ y $\Gamma_q = \mathbb{E}(V_t' V_t) = [\mathbb{E}(X_t X_j)]_{i,j=1}^p$. Por lo tanto,

$$\hat{\boldsymbol{\theta}} \xrightarrow{d} N\left(\boldsymbol{\theta}, \frac{\sigma^2\,\Gamma_q^{-1}}{T}\right).$$

Ejemplo 2.59 (MA(1))**.** Análogamente al caso del AR(1), se tiene que

$$\hat{\theta} \xrightarrow{d} N\left(\theta, \frac{1-\theta^2}{T}\right).$$

Es decir, la varianza de la estimación será menor cuanto mayor sea el tamaño muestral y cuanto más próximo sea el parámetro θ a 1.

Ejemplo 2.60 (MA(2))**.**

$$\begin{pmatrix}\hat{\theta}_1\\ \hat{\theta}_2\end{pmatrix} \xrightarrow{d} N\left(\begin{pmatrix}\theta_1\\ \theta_2\end{pmatrix}, \frac{1}{T}\begin{pmatrix}1-\theta_2^2 & \theta_1(1-\theta_2)\\ \theta_1(1-\theta_2) & 1-\theta_2^2\end{pmatrix}\right).$$

Ejemplo 2.61 (ARMA(1,1))**.**

$$V(\phi,\theta) = \sigma^2\begin{bmatrix}\mathbb{E}(U_t^2) & \mathbb{E}(U_t V_t')\\ \mathbb{E}(U_t V_t') & \mathbb{E}(V_t^2)\end{bmatrix}^{-1} = \begin{bmatrix}(1-\phi^2)^{-1} & (1+\phi\theta)^{-1}\\ (1+\phi\theta)^{-1} & (1-\theta^2)^{-1}\end{bmatrix}^{-1},$$

donde $U_t - \phi U_{t-1} = Z_t$ y $V_t + \theta V_{t-1} = Z_t$. Entonces,

$$\begin{pmatrix}\hat{\theta}_1\\ \hat{\theta}_2\end{pmatrix} \xrightarrow{d} N\left(\begin{pmatrix}\theta_1\\ \theta_2\end{pmatrix}, \frac{1+\phi\theta}{T(\phi+\theta)^2}\begin{pmatrix}(1-\phi^2)(1+\phi\theta) & -(1-\theta^2)(1-\phi^2)\\ -(1-\theta^2)(1-\phi^2) & (1-\theta^2)(1+\phi\theta)\end{pmatrix}\right).$$

A partir de estas distribuciones se podrá hacer inferencia, calculando regiones de confianza asintóticas o estadísticos para contrastes de hipótesis.

2.7. Selección de modelos mediante el criterio de información de Akaike

Cuando se dispone de varios modelos ajutados a una muestra, es necesario disponer de un criterio para seleccionar uno de ellos. Antes de establecer un criterio, es conveniente tener en cuenta que aumentar el número de parámetros de los modelos siempre supone una mayor verosimilitud. No obstante, un modelo excesivamente complejo puede tener sobreajuste. Por lo tanto, se buscará un criterio que tenga en cuenta tanto la bondad del ajuste como la complejidad del mismo (número de parámetros). Uno de los más usados es el criterio de información de Akaike.

Tal y como se describe en la sección 9.3 de [3], este criterio surgió como propuesta de estimador de la divergencia de Kullback-Leibler (KL), que mide la discrepancia entre la distribución verdadera de los datos y un modelo propuesto. Dado que la distribución verdadera es desconocida, será necesario estimar dicha discrepancia, y seleccionar el modelo que tenga menor discrepancia. Akaike propuso el siguiente estimador, el cual recibe el nombre de criterio de información de Akaike:

$$\mathrm{AIC}(\boldsymbol{\beta}, \sigma) := -2\log(L(\boldsymbol{\beta}, \sigma)) + 2k,$$

donde k es el número de parámetros a estimar. Para un proceso ARMA(p, q) de media nula, $k = p + q + 1$.

No obstante, como el estimador anterior es sesgado, se propuso el criterio de información de Akaike corregido, el cual es insesgado:

$$\mathrm{AICc}(\boldsymbol{\beta}, \sigma) := -2\log(L(\boldsymbol{\beta}, \sigma)) + 2\frac{kT}{T-k-1}, \tag{2.26}$$

donde T es el tamaño muestral.

2.8. Metodología para el análisis de series de tiempo

En [1] se propone la metodología Box-Jenkins para llevar a cabo el análisis de una serie de tiempo, la cual se puede resumir en las siguientes etapas:

1. Identificar un conjunto de modelos compatibles con la serie de tiempo a analizar. Para ello, será necesario:

    a) Decidir las transformaciones necesarias para convertir la serie observada en estacionaria, en caso de que no lo sea. En concreto, la serie transformada deberá tener una varianza y una media constante a lo largo del tiempo.

b) Proponer los órdenes de los modelos ARMA o ARMA estacional compatibles con la serie observada.

Estos dos pasos se podrán realizar, por ejemplo, observando el gráfico secuencial de la serie, y las funciones de autocorrelación simple y autocorrelación parcial muestrales de la misma.

2. Realizar la estimación de varios modelos, y seleccionar el mejor en base a algún criterio, como el AICc (2.26). El conjunto de los modelos candidatos contiene los modelos propuestos en la primera etapa.

3. Etapa de diagnosis, con el fin de comprobar que el modelo propuesto es adecuado, en el sentido de que cumple las hipótesis de los modelos ARMA.

2.8.1. Etapa 1: Identificación de modelos compatibles con la serie de tiempo

Para poder identificar los modelos compatibles con la serie de tiempo, es necesario que la serie sea estacionaria. Por lo tanto, el primer paso será transformar la serie original en una serie estacionaria. Para contrastar si la serie es estacionaria, o bien se podría aplicar un test de raíz unitaria, como el test de Dickey-Fuller, o bien se pueden seguir los pasos que se describen a continuación.

Transformaciones para estabilizar la varianza de la serie

De forma cualitativa, un indicio de que la serie de tiempo no tiene varianza constante a lo largo del tiempo, es que las oscilaciones de la serie aumentan a medida que el nivel de la serie aumenta. Una primera forma de comprobar esto cuantitativamente sería hacer grupos de observaciones contiguas de la series, y calcular la media y la varianza de cada grupo. Graficando la varianza de cada grupo frente a la media, se puede observar si hay correlación entre ambas, en cuyo caso, la varianza no es constante a lo largo del tiempo. Los grupos deberían estar formados por 5 o 6 observaciones para series no estacionales, mientras que para las estacionales, por tantas como el período estacional.

La forma más habitual de estabilizar la varianza de una serie de tiempo cuyos valores son todos positivos, es aplicar una transformación de Box-Cox a la serie. Sea $\{x_t\}$ la serie original, la serie transformada $\{y_t\}$ sería:

$$y_t = \begin{cases} \dfrac{x_t^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0, \\ \log(x_t) & \text{si } \lambda = 0. \end{cases}$$

Si la desviación típica es una función potencial de la media, i.e., si $\sigma_t = k\mu_t^{1-\lambda}$, entonces se puede

demostrar que la transformación de Box-Cox[4] con parámetro λ consigue estabilizar la varianza de la serie. Para estimar el valor de λ en este caso, teniendo en cuenta que

$$\sigma_t = k\mu_t^{1-\lambda} \iff \log(\sigma_t) = \log(k) + (1-\lambda)\log(\mu_t),$$

y a partir de los grupos anteriormente definidos, se puede estimar $1-\lambda$ como la pendiente de la recta de regresión de $\log(\sigma_t)$ en función de $\log(\mu_t)$.

Transformación para estabilizar la media de la serie

La presencia de tendencia en la serie se puede identificar, en primer lugar, a partir del gráfico secuencial de la misma; o en segundo lugar, a partir del gráfico de la función de autocorrelaciones simples, la cual debe mostrar un decrecimiento lento y lineal. Para estabilizar la media de la serie, se puede aplicar diferencias regulares, tal y como se expuso en la Sección 2.4.1.

Eliminación de la estacionalidad

El último paso para obtener una serie estacionaria sería eliminar la componente estacional. Para ello, se pueden aplicar diferencias estacionales de período estacional s, el cual se podría identificar observando patrones repetitivos en el gráfico secuencial de la serie temporal. Además, este comportamiento también se podría identificar la función de autocorrelación simple, ya que esta tomará valores positivos que decrecen lentamente en los retardos que son múltiplos del período estacional.

Identificación del orden del modelo ARMA

La serie obtenida tras haber aplicado las trasformaciones anteriores debería ser un proceso estacionario. Por lo tanto, podría ser modelada mediante un proceso ARMA o ARMA estacional. Entonces, será necesario identificar los órdenes del modelo en cuestión.

No obstante, es conveniente tener en cuenta que, para procesos modelos mixtos, la estructura de correlación es compleja, y su estimación resulta complicada. Por lo tanto, en esta primera etapa no se propondrán modelos mixtos, sino que será en la etapa 2 cuando podrán aparecer y ser seleccionados usando criterios de selección más objetivos.

Teniendo esto en cuenta, para proponer los modelos candidatos en esta primera etapa, se observa el gráfico de la fas (2.5) y fap (Sección 2.1.3) muestrales, y se proponen modelos siguiendo los siguientes criterios.

[4]Transformación visitada en la materia de Inferencia Estadística del Grado en Matemáticas.

- En el caso de series no estacionales, se propone un modelo AR(p) si p es el mayor retardo significativamente no nulo de la fap, y un modelo MA(q) si q es el mayor retardo significativamente no nulo de la fas.
- En el caso de series estacionales, se sigue el criterio anterior para los órdenes regulares del proceso, pero considerando solamente los retardos $\{1, \ldots, \lfloor s/2 \rfloor\}$, donde s es el período estacional. Con respecto a los órdenes estacionales, los órdenes P y Q se proponen como el mayor retardo estacional (aquellos que son múltiplo de s) significativamente no nulo de la fap y fas, respectivamente. Por otra parte, es resultar interesante saber que:
  - En la fas, a ambos lados de cada retardo estacional se produce una repetición de la forma de la fas de la parte regular (invertida, si la fas en el retardo estacional es negativa).
  - En la fap, a la izquierda de cada retardo estacional se produce una repetición de la forma de la fas de la parte regular (invertida, si la fap en el retardo estacional es negativa). En cambio, a la derecha de cada retardo estacional, aparecerá la fap de la parte regular (invertida, si la fap en el retardo estacional es positiva).

2.8.2. Etapa 2: Estimación de los modelos candidatos

Se realiza la estimación de los modelos candidatos de la etapa anterior, y se selecciona el mejor modelo en base a algún criterio de selección, como el AICc.

No obstante, en la práctica también se pueden estimar todos los modelos que cumplan una serie de restricciones en sus órdenes, y seleccionar el mejor modelo en base a algún criterio de selección, como el AICc.

2.8.3. Etapa 3: Diagnosis del modelo

Al proponer un modelo para una serie de tiempo es importante comprobar que las hipótesis básicas de dicho modelo no se incumplen. Para los modelos utilizados en el presente Trabajo Fin de Grado, será necesario comprobar que los residuos (estimación de las innovaciones) provienen de un proceso de ruido blanco. Es decir, se comprobará que tienen media nula, que tienen varianza constante (homocedasticidad), y que están incorrelados. Además, en caso de suponer que el proceso generador de la serie es gaussiano, será necesario constrastar si dichos residuos son normales.

2.8.4. Constraste de raíz unitaria Dickey-Fuller

Este contraste permite contrastar la hipótesis nula de que la serie tiene una raíz unitaria, es decir, que es no estacionaria, frente a la alternativa de que la serie es estacionaria. Es una prueba habitual antes de ajustar un modelo a una serie de tiempo.

Para procesos AR(1), se propone ajustar el siguiente modelo: $(1-B)X_t = \alpha X_{t-1} + Z_t$. Bajo la hipótesis nula, $\alpha = 0$, y bajo la alternativa, $\alpha < 0$. El estadístico del contraste es $t = \dfrac{\hat{\alpha}}{\hat{\sigma}(\hat{\alpha})}$, cuya distribución bajo la hipótesis nula fue tabulada por Dickey y Fuller [6]. Este contraste se puede generalizar tanto para procesos AR(p) como para procesos ARMA(p, q) tal y como se muestra en [5].

2.8.5. Incorrelación de los residuos

Será necesario constrastar la hipótesis nula de que los residuos son incorrelados frente a la alternativa de que son correlados. Se comentan a continuación dos formas de proceder.

Función de autocorrelaciones simples de los residuos

Si los residuos son realmente ruido blanco, razonando del mismo modo que en la Sección 2.3.1, se tiene que

$$\hat{\rho}_h \xrightarrow{d} N\left(0,\ \frac{1}{T}\right) \quad \forall h \geq 1,$$

donde $\hat{\rho}_h$ es la estimación muestral de la autocorrelación de los residuos en el retardo h.

El estadístico de contraste resultante es $\sqrt{T}\hat{\rho}_h$, y para un nivel de significación individual aproximado del 5 % se rechaza la hipótesis nula de incorrelación de los residuos ($\rho_h = 0\ \forall h > 0$) si el valor absoluto de dicho estadístico es mayor que 1.96.

Test de Ljung-Box

Este test propone el siguiente estadístico para realizar el contraste de incorrelación:

$$Q(h) = T(T+2)\sum_{j=1}^{h} \frac{\hat{\rho}_j^2}{T-j}.$$

Bajo la hipótesis nula de incorrelación, $Q(h)$ sigue aproximadamente una distribución χ^2 con tantos grados de libertad como h menos el número de parámetros estimados. Por ejemplo, para un modelo ARMA(p, q) en el que es necesario estimar la media, el número de grados de libertad es $p + q + 2$.

Se observa que el estadístico de este contraste da el mismo peso a todos los horizontes temporales. No obstante, podría ser más adecuado dar más peso a los valores de h más pequeños. En el Capítulo 11 de [5] se propone el denominado constraste del determinante, que modifica el test de Ljung-Box ponderando más los retardos iniciales.

2.8.6. Media de los residuos

Asumiendo que $\mathbb{E}(Z_t) = \mu \ \forall t$, se desea contrastar la hipótesis nula $H_0 : \mu = 0$ frente a la alternativa $H_1 : \mu \neq 0$, para verificar si los residuos tienen media cero. Para ello se emplea la prueba t de Student para una media muestral, cuyo estadístico es $\bar{a}/(s_a/\sqrt{T})$, donde $\bar{a}$ es la media de los residuos, s_a su desviación típica muestral y T el tamaño de la muestra. Bajo normalidad, este estadístico sigue exactamente una distribución t de Student con $T-1$ grados de libertad. No obstante, la normalidad de los residuos no es estrictamente necesaria: por el teorema central del límite, si T es suficientemente grande y la distribución de los residuos no es excesivamente asimétrica, la distribución de $\bar{a}$ se aproxima a la normal. Además, el teorema de Slutsky garantiza que, bajo convergencia en probabilidad de s_a^2 a σ^2, el estadístico en cuestión converge en distribución a una normal estándar, incluso cuando los residuos no son normales. Por lo tanto, en muestras grandes, la prueba t es válida de forma aproximada aunque no se cumpla la normalidad de los residuos.

Capítulo 3

Ilustración de los procesos de estimación y predicción mediante un estudio de simulación

En este capítulo se simularán diferentes procesos para evaluar la bondad de los métodos de estimación y predicción expuestos en el capítulo anterior.

Tanto para el estudio de estimación como para el de predicción se utilizó la función `sarima.sim` del paquete `astsa` de R para simular series. Para realizar el ajuste de los modelos, se utilizó la función `Arima` del paquete `forecast`. Además, de este último paquete también se usó la función `forecast` para realizar las predicciones.

3.1. Estimación

Con el fin comprobar la bondad de los estimadores de los parámetros de los modelos expuestos en el capítulo anterior, se realizó un estudio de simulación, el cual consistió en generar realizaciones muestrales de procesos artificialmente para comprobar si los estimadores proporcionan valores cercanos a los reales.

En cada simulación se generarán artificialmente B series de tiempo de tamaño T, y para cada una de ellas se realizará el ajuste del modelo por máxima verosimilitud exacta. Entonces, se dispondrán de B estimaciones de parámetros, con las cuales se podrá estimar el sesgo y la varianza de los estimadores, además de poder contrastar su distribución. En cada simulación se escogerán los siguientes parámetros:

- B: El número de repeticiones de cada simulación, es decir, el número de veces que se genera artificialmente una serie de tiempo. Se tomará $B = 500$.
- T: El tamaño muestral de la serie de tiempo. Se probarán algunos de los siguientes valores de T: $20, 50, 100, 500$.
- Los parámetros $\boldsymbol{\beta} = (\boldsymbol{\phi}, \boldsymbol{\theta})'$ de los modelos a simular.
- μ: Media del proceso. Se tomará $\mu = 0$.
- σ^2: Varianza de las innovaciones. Se probará algunos de los siguientes valores: $1, 9$ y 81.

En la Sección 2.6.2 se vio que $\boldsymbol{\beta}$ converge a una distribución normal multivariante. Es por ello que además de estimar el sesgo, la varianza y el error cuadrático medio de cada simulación, también se realizará un test de normalidad. En este caso, se utilizará la versión multivariante del test de Shapiro-Wilk, el cual se realizará sobre una muestra de tamaño B.

3.1.1. Simulación de procesos AR

Según se expuso en el Ejemplo 2.57, para un proceso AR(1) se tiene que

$$\hat{\phi} \xrightarrow{d} N\left(\phi, \frac{1-\phi^2}{T}\right). \tag{3.1}$$

A la vista de la expresión anterior, parece que la varianza de las innovaciones no tienen ningún efecto sobre la estimación del parámetro ϕ. No obstante, para este primer proceso se probarán varios valores de σ^2, para comprobar de forma empírica el resultado teórico anterior. Además, se aprovechará para comprobar el efecto del valor de σ^2 sobre su estimación.

En el Tabla 3.1 se muestra el resultado de las diferentes simulaciones. Se pueden extraer las siguientes conclusiones:

- La estimación del sesgo de $\hat{\phi}$ disminuye a medida que se aumenta el tamaño muestral de la serie (T), lo cual concuerda con que los estimadores usados son asintóticamente insesgados. Además, el hecho de que la estimación de la varianza de $\hat{\phi}$ también disminuya al aumentar T, concuerda con la propiedad de consistencia de dichos estimadores. Consecuentemente, la estimación del error cuadrático medio (ECM) de $\hat{\phi}$ también disminuye al aumentar T.
- La estimación de la varianza de $\hat{\phi}$ disminuye al aumentar el valor del parámetro ϕ. Esto es coherente con el hecho de que la varianza asintótica del estimador es proporcional a $1-\phi^2$. Además, esto concuerda con la intuición de que a menor valor absoluto de ϕ, menor correlación temporal tendrá la serie, por lo que será más complicado distinguir la señal del ruido, de ahí que el estimador tenga mayor varianza.

- La estimación del sesgo de $\hat{\phi}$ ha resultado positiva en todos los casos. Entonces, se puede suponer que para un ϕ positivo, el estimador tiende a sobrestimar el parámetro.

- Con respecto a la estimación de μ, esta empeora (en cuanto a estimación del sesgo, varianza y ECM) cuanto mayor sea $|\phi|$. Esto es lógico, ya que cuanto mayor sea $|\phi|$, mayor será la correlación temporal, por lo que más tiempo se quedará la serie en valores parecidos a los anteriores, arriba o abajo del 0, siendo más complicado estimar μ. Además, esto va en línea con la expresión de la varianza de la media muestral (2.4).

- El valor de σ^2 no afecta a la estimación del parámetro ϕ. Esto es coherente con la expresión (3.1). Además, concuerda con el hecho de que el valor de σ solo determina la escala de la serie. De hecho, si se generan dos series de tiempo a partir del mismo proceso y con la misma semilla, sus valores son proporcionales, y los gráficos secuenciales solo se diferencian en la escala del eje vertical.

- Con respecto a la estimación de σ^2, la estimación de su sesgo y varianza aumentan proporcionalmente al aumentar el valor de σ^2. Esto es lógico, ya que si se aumenta el valor de σ^2, se aumenta la escala de la serie, por lo que los valores de las estimaciones también aumentan.

- El p-valor obtenido del test de Shapiro-Wilk para contrastar la normalidad de $\hat{\phi}$ es mayor cuanto mayor sea el tamaño muestral T. Esto es lógico, ya que se tiene que el estimador es asintóticamente normal, y para que se de la normalidad, el valor de T tiene que ser lo suficientemente grande.

  Por otra parte, los p-valores obtenidos son mayores cuanto más próximo a 0 sea ϕ. Esto es esperable, ya que como $|\phi| < 1$, cuanto más próximo a 0 sea ϕ, mayor simetría entorno a ϕ puede haber. En cambio, para las simulaciones realizadas para $\phi = 0.9$ se rechaza siempre la normalidad, incluso con $T = 500$. Esto no va en contra de la expresión (3.1), sino que simplemente 500 no es un tamaño muestral suficiente para tener normalidad. De hecho, se ha probado con $T = 5000$, y el p-valor obtenido es de 0.0259, mientras que para $T = 50000$, el p-valor es 0.3646.

Con el objetivo de aligerar las tablas de resultados, en las siguientes simulaciones solo se probará un único valor de σ^2, concretamente $\sigma^2 = 1$. Además, tampoco se mostrarán los resultados relativos a la estimación de μ, y σ^2.

	T	20			50			100			500		
σ^2	ϕ	0.1	0.5	0.9	0.1	0.5	0.9	0.1	0.5	0.9	0.1	0.5	0.9
1	$\widehat{\mathbb{E}}(\hat{\phi}-\phi)$	0.072	0.124	0.198	0.034	0.050	0.082	0.012	0.034	0.037	−0.001	0.004	0.006
	$\widehat{\mathbb{E}}(\hat{\mu}-\mu)$	0.002	−0.019	0.006	0.003	−0.005	−0.050	−0.002	−0.001	0.019	0.001	0.001	0.013
	$\widehat{\mathbb{E}}(\hat{\sigma}^2-\sigma^2)$	0.095	0.108	0.117	0.042	0.039	0.042	0.016	0.018	0.022	0.004	0.007	0.003
	$\widehat{\mathrm{Var}}(\hat{\phi})$	0.045	0.045	0.037	0.022	0.016	0.009	0.010	0.008	0.003	0.002	0.002	0.000
	$\widehat{\mathrm{Var}}(\hat{\mu})$	0.056	0.201	3.243	0.023	0.075	1.585	0.012	0.038	0.777	0.002	0.007	0.183
	$\widehat{\mathrm{Var}}(\hat{\sigma}^2)$	0.086	0.091	0.083	0.037	0.040	0.036	0.018	0.020	0.019	0.004	0.004	0.004
	$\widehat{ECM}(\hat{\phi})$	0.050	0.060	0.076	0.023	0.018	0.015	0.010	0.009	0.005	0.002	0.002	0.000
	$\widehat{ECM}(\hat{\mu})$	0.056	0.201	3.243	0.023	0.075	1.587	0.012	0.038	0.778	0.002	0.007	0.183
	$\widehat{ECM}(\hat{\sigma}^2)$	0.095	0.103	0.097	0.039	0.041	0.038	0.019	0.020	0.019	0.004	0.004	0.004
	p-valor	0.296	0.006	0.000	0.536	0.001	0.000	0.635	0.000	0.000	0.521	0.305	0.000
9	$\widehat{\mathbb{E}}(\hat{\phi}-\phi)$	0.060	0.131	0.199	0.024	0.041	0.077	0.016	0.023	0.038	0.001	0.003	0.007
	$\widehat{\mathbb{E}}(\hat{\mu}-\mu)$	−0.020	−0.030	−0.029	−0.001	0.019	0.010	−0.010	−0.004	0.039	−0.011	−0.015	0.114
	$\widehat{\mathbb{E}}(\hat{\sigma}^2-\sigma^2)$	0.774	0.980	1.045	0.367	0.368	0.377	0.105	0.166	0.271	0.046	0.058	0.067
	$\widehat{\mathrm{Var}}(\hat{\phi})$	0.047	0.047	0.035	0.021	0.016	0.008	0.010	0.008	0.003	0.002	0.002	0.000
	$\widehat{\mathrm{Var}}(\hat{\mu})$	0.543	1.703	24.372	0.221	0.726	14.038	0.111	0.332	7.877	0.022	0.063	1.940
	$\widehat{\mathrm{Var}}(\hat{\sigma}^2)$	6.550	7.410	7.080	3.438	2.982	2.761	1.519	1.704	1.629	0.308	0.315	0.345
	$\widehat{ECM}(\hat{\phi})$	0.051	0.064	0.075	0.022	0.018	0.014	0.010	0.009	0.004	0.002	0.002	0.000
	$\widehat{ECM}(\hat{\mu})$	0.544	1.704	24.373	0.221	0.726	14.038	0.111	0.332	7.879	0.022	0.063	1.953
	$\widehat{ECM}(\hat{\sigma}^2)$	7.148	8.370	8.173	3.572	3.117	2.903	1.530	1.731	1.703	0.310	0.318	0.350
	p-valor	0.046	0.000	0.000	0.562	0.014	0.000	0.972	0.000	0.000	0.503	0.250	0.000
81	$\widehat{\mathbb{E}}(\hat{\phi}-\phi)$	0.069	0.136	0.196	0.031	0.053	0.077	0.011	0.025	0.034	0.002	0.003	0.009
	$\widehat{\mathbb{E}}(\hat{\mu}-\mu)$	−0.030	−0.173	−0.617	−0.118	0.051	0.220	−0.003	0.003	−0.323	−0.059	−0.023	0.256
	$\widehat{\mathbb{E}}(\hat{\sigma}^2-\sigma^2)$	6.720	9.303	9.260	3.282	3.739	2.996	0.929	1.949	2.546	0.529	0.265	0.545
	$\widehat{\mathrm{Var}}(\hat{\phi})$	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.00	0.00	0.00
	$\widehat{\mathrm{Var}}(\hat{\mu})$	5.2	16.7	237.1	2.1	6.4	126.9	1.0	3.3	64.9	0.22	0.60	16.24
	$\widehat{\mathrm{Var}}(\hat{\sigma}^2)$	592.3	600.2	579.9	258.0	272.2	234.1	126.9	129.1	125.5	25.47	26.52	27.01
	$\widehat{ECM}(\hat{\phi})$	0.1	0.1	0.1	0.0	0.0	0.0	0.0	0.0	0.0	0.00	0.00	0.00
	$\widehat{ECM}(\hat{\mu})$	5.2	16.7	237.5	2.1	6.4	127.0	1.0	3.3	65.0	0.22	0.60	16.31
	$\widehat{ECM}(\hat{\sigma}^2)$	637.5	686.7	665.6	268.8	286.2	243.1	127.8	132.9	132.0	25.75	26.59	27.31
	p-valor	0.063	0.000	0.000	0.449	0.000	0.000	0.042	0.328	0.000	0.173	0.572	0.000

Tabla 3.1: Resultados de la estimación de procesos AR(1), donde ECM denota el error cuadrático medio, y el p-valor corresponde al test de normalidad de $\hat{\phi}$.

T	20			50			100			500		
θ	0.1	0.5	0.9	0.1	0.5	0.9	0.1	0.5	0.9	0.1	0.5	0.9
$\widehat{\mathbb{E}}(\hat{\theta}-\theta)$	0.091	0.001	0.032	0.025	−0.009	−0.010	0.004	0.001	−0.014	−0.003	−0.001	−0.003
$\widehat{\mathrm{Var}}(\hat{\theta})$	0.133	0.083	0.050	0.026	0.024	0.008	0.011	0.010	0.003	0.002	0.001	0.000
$\widehat{ECM}(\hat{\theta})$	0.141	0.083	0.051	0.027	0.024	0.008	0.011	0.010	0.003	0.002	0.001	0.000
p-valor	0.000	0.000	0.000	0.142	0.000	0.000	0.778	0.005	0.000	0.845	0.032	0.026

Tabla 3.2: Resultados de la estimación de procesos MA(1), donde ECM denota el error cuadrático medio, y el p-valor corresponde al test de normalidad de $\hat{\theta}$.

3.1.2. Simulación de procesos MA

Según se expuso en el Ejemplo 2.59, para un proceso AR(1) se tiene que

$$\hat{\theta} \xrightarrow{d} N\left(\theta, \frac{1-\theta^2}{T}\right). \tag{3.2}$$

La expresión anterior es análoga a la de (3.1), por lo que las conclusiones que se pueden extraer sobre la influencia del tamaño muestral T y del parámetro θ sobre la calidad de la estimación de θ son las mismas que las extraídas en el caso del proceso AR(1). Además, a la vista de (3.2), el valor de σ^2 no afecta a la estimación θ. En la Tabla 3.2 se muestran el resultado de las diferentes simulaciones, donde las conclusiones que se pueden extraer son las siguientes:

- Al aumentar el tamaño muestral T, disminuye la estimación del sesgo, la varianza y el error cuadrático medio de $\hat{\theta}$. Además, al aumentar T también aumenta el p-valor del test de normalidad.
- Al aumentar el valor absoluto del parámetro θ, disminuye la varianza de la estimación de θ. Además, cuanto más cerca esté θ de 0, más simétrica será la distribución de las estimaciones, por lo que el p-valor del test de normalidad también aumentará.

3.1.3. Simulación de procesos ARMA

En el Ejemplo 2.61 se vio que para un proceso ARMA(1,1) se tiene que

$$\begin{pmatrix}\hat{\phi}\\ \hat{\theta}\end{pmatrix} \xrightarrow{d} N\left(\begin{pmatrix}\phi\\ \theta\end{pmatrix}, \frac{1+\phi\theta}{T(\phi+\theta)^2}\begin{bmatrix}(1-\phi^2)(1+\phi\theta) & -(1-\theta^2)(1-\phi^2)\\ -(1-\theta^2)(1-\phi^2) & (1-\theta^2)(1+\phi\theta)\end{bmatrix}\right).$$

La estructura de la matriz de covarianzas es más compleja en este caso. En la Tabla 3.3 se muestran los resultados de las diferentes simulaciones. La conclusión más novedosa es que el

T	50					100					500				
$\begin{bmatrix}\phi\\ \theta\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.9\\0.1\end{bmatrix}$	$\begin{bmatrix}0.5\\0.5\end{bmatrix}$	$\begin{bmatrix}0.1\\0.9\end{bmatrix}$	$\begin{bmatrix}0.9\\0.9\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.9\\0.1\end{bmatrix}$	$\begin{bmatrix}0.5\\0.5\end{bmatrix}$	$\begin{bmatrix}0.1\\0.9\end{bmatrix}$	$\begin{bmatrix}0.9\\0.9\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.9\\0.1\end{bmatrix}$	$\begin{bmatrix}0.5\\0.5\end{bmatrix}$	$\begin{bmatrix}0.1\\0.9\end{bmatrix}$	$\begin{bmatrix}0.9\\0.9\end{bmatrix}$
$\begin{bmatrix}\widehat{\mathbb{E}}(\hat{\phi}-\phi)\\ \widehat{\mathbb{E}}(\hat{\theta}-\theta)\end{bmatrix}$	$\begin{bmatrix}0.079\\-0.071\end{bmatrix}$	$\begin{bmatrix}0.093\\-0.047\end{bmatrix}$	$\begin{bmatrix}0.069\\-0.050\end{bmatrix}$	$\begin{bmatrix}0.015\\-0.017\end{bmatrix}$	$\begin{bmatrix}0.073\\-0.026\end{bmatrix}$	$\begin{bmatrix}0.068\\-0.066\end{bmatrix}$	$\begin{bmatrix}0.046\\-0.031\end{bmatrix}$	$\begin{bmatrix}0.037\\-0.024\end{bmatrix}$	$\begin{bmatrix}0.009\\-0.013\end{bmatrix}$	$\begin{bmatrix}0.038\\-0.012\end{bmatrix}$	$\begin{bmatrix}0.019\\-0.018\end{bmatrix}$	$\begin{bmatrix}0.008\\-0.002\end{bmatrix}$	$\begin{bmatrix}0.005\\-0.003\end{bmatrix}$	$\begin{bmatrix}-0.002\\-0.001\end{bmatrix}$	$\begin{bmatrix}0.007\\-0.003\end{bmatrix}$
$\begin{bmatrix}\widehat{\mathrm{Var}}(\hat{\phi})\\ \widehat{\mathrm{Var}}(\hat{\theta})\end{bmatrix}$	$\begin{bmatrix}0.222\\0.279\end{bmatrix}$	$\begin{bmatrix}0.014\\0.027\end{bmatrix}$	$\begin{bmatrix}0.028\\0.028\end{bmatrix}$	$\begin{bmatrix}0.022\\0.010\end{bmatrix}$	$\begin{bmatrix}0.008\\0.005\end{bmatrix}$	$\begin{bmatrix}0.190\\0.191\end{bmatrix}$	$\begin{bmatrix}0.005\\0.013\end{bmatrix}$	$\begin{bmatrix}0.013\\0.013\end{bmatrix}$	$\begin{bmatrix}0.011\\0.004\end{bmatrix}$	$\begin{bmatrix}0.003\\0.003\end{bmatrix}$	$\begin{bmatrix}0.059\\0.060\end{bmatrix}$	$\begin{bmatrix}0.001\\0.002\end{bmatrix}$	$\begin{bmatrix}0.002\\0.003\end{bmatrix}$	$\begin{bmatrix}0.003\\0.001\end{bmatrix}$	$\begin{bmatrix}0.000\\0.000\end{bmatrix}$
$\begin{bmatrix}\widehat{ECM}(\hat{\phi})\\ \widehat{ECM}(\hat{\theta})\end{bmatrix}$	$\begin{bmatrix}0.228\\0.284\end{bmatrix}$	$\begin{bmatrix}0.022\\0.029\end{bmatrix}$	$\begin{bmatrix}0.033\\0.031\end{bmatrix}$	$\begin{bmatrix}0.022\\0.010\end{bmatrix}$	$\begin{bmatrix}0.013\\0.006\end{bmatrix}$	$\begin{bmatrix}0.195\\0.195\end{bmatrix}$	$\begin{bmatrix}0.007\\0.014\end{bmatrix}$	$\begin{bmatrix}0.014\\0.013\end{bmatrix}$	$\begin{bmatrix}0.011\\0.004\end{bmatrix}$	$\begin{bmatrix}0.005\\0.003\end{bmatrix}$	$\begin{bmatrix}0.060\\0.061\end{bmatrix}$	$\begin{bmatrix}0.001\\0.002\end{bmatrix}$	$\begin{bmatrix}0.002\\0.003\end{bmatrix}$	$\begin{bmatrix}0.003\\0.001\end{bmatrix}$	$\begin{bmatrix}0.000\\0.000\end{bmatrix}$
p-valor	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.419	0.017	0.000

Tabla 3.3: Resultados de la estimación ARMA(1,1), donde ECM denota el error cuadrático medio, y el p-valor corresponde al test de normalidad del vector $(\hat{\phi}, \hat{\theta})'$.

valor de un parámetro afecta a la estimación del otro. En concreto, cuanto mayor sea el valor absoluto del parámetro, menor será la estimación del sesgo y la varianza de la estimación de los dos parámetros. Además, al igual que en las simulaciones anteriores, al aumentar el tamaño muestral T, disminuye la estimación del sesgo, la varianza y el error cuadrático medio de las estimaciones.

Con respecto al test de normalidad, para cualquier nivel de significación habitual solo se acepta la hipótesis nula para el caso en que $T = 500$ y $\phi = 0.5$, $\theta = 0.5$. El motivo de que se rechace para el resto de los casos, podría ser que el tamaño muestral T no es lo suficientemente grande para que se de la normalidad, ya que la expresión de la convergencia en distribución de los estimadores es asintótica.

3.1.4. Simulación de procesos SARIMA

Teniendo en cuenta que este modelo tiene un número de parámetros mayor, y que el modelo es estacional, es conveniente aumentar el tamaño muestral T mínimo evitar errores en la función de estimación. En concreto, se ha probado con $T = 50, 100, 500$.

En la Tabla 3.4 se muestran los resultados de las simulaciones de un SARIMA(1,0,1)(1,0,1)$_4$. Las conclusiones que se pueden extraer son las mismas que en los casos anteriores, es decir, al aumentar el tamaño muestral T se obtienen estimaciones mejores. Por otra parte, para estos tamaños muestrales el test de normalidad rechaza la hipótesis nula de normalidad, para cualquier nivel de significación habitual.

Otro comportamiento observado, es que aumentar el valor absoluto de los parámetros ϕ y θ, no parece afectar a la estimación de los parámetros estacionales, y viceversa.

T	50				100				500			
$\begin{bmatrix}\phi\\ \theta\\ \Phi\\ \Theta\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\\0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.5\\0.5\\0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\\0.5\\0.5\end{bmatrix}$	$\begin{bmatrix}0.9\\0.9\\0.9\\0.9\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\\0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.5\\0.5\\0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\\0.5\\0.5\end{bmatrix}$	$\begin{bmatrix}0.9\\0.9\\0.9\\0.9\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\\0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.5\\0.5\\0.1\\0.1\end{bmatrix}$	$\begin{bmatrix}0.1\\0.1\\0.5\\0.5\end{bmatrix}$	$\begin{bmatrix}0.9\\0.9\\0.9\\0.9\end{bmatrix}$
$\begin{bmatrix}\widehat{\mathbb{E}}(\hat{\phi}-\phi)\\ \widehat{\mathbb{E}}(\hat{\theta}-\theta)\\ \widehat{\mathbb{E}}(\hat{\Phi}-\Phi)\\ \widehat{\mathbb{E}}(\hat{\Theta}-\Theta)\end{bmatrix}$	$\begin{bmatrix}-0.031\\0.025\\0.005\\-0.015\end{bmatrix}$	$\begin{bmatrix}0.030\\-0.017\\0.036\\-0.039\end{bmatrix}$	$\begin{bmatrix}0.004\\-0.007\\0.018\\-0.019\end{bmatrix}$	$\begin{bmatrix}0.016\\0.023\\0.037\\0.074\end{bmatrix}$	$\begin{bmatrix}-0.006\\-0.003\\0.038\\-0.044\end{bmatrix}$	$\begin{bmatrix}0.013\\-0.010\\0.012\\-0.006\end{bmatrix}$	$\begin{bmatrix}0.003\\-0.004\\0.026\\-0.024\end{bmatrix}$	$\begin{bmatrix}0.016\\0.006\\0.021\\0.006\end{bmatrix}$	$\begin{bmatrix}0.011\\-0.012\\-0.001\\0.004\end{bmatrix}$	$\begin{bmatrix}-0.003\\0.002\\0.007\\-0.003\end{bmatrix}$	$\begin{bmatrix}-0.002\\-0.001\\0.004\\-0.001\end{bmatrix}$	$\begin{bmatrix}0.015\\0.005\\0.011\\0.015\end{bmatrix}$
$\begin{bmatrix}\widehat{\mathrm{Var}}(\hat{\phi})\\ \widehat{\mathrm{Var}}(\hat{\theta})\\ \widehat{\mathrm{Var}}(\hat{\Phi})\\ \widehat{\mathrm{Var}}(\hat{\Theta})\end{bmatrix}$	$\begin{bmatrix}0.268\\0.308\\0.257\\0.321\end{bmatrix}$	$\begin{bmatrix}0.032\\0.038\\0.263\\0.320\end{bmatrix}$	$\begin{bmatrix}0.240\\0.272\\0.033\\0.058\end{bmatrix}$	$\begin{bmatrix}0.008\\0.012\\0.010\\0.018\end{bmatrix}$	$\begin{bmatrix}0.197\\0.209\\0.203\\0.207\end{bmatrix}$	$\begin{bmatrix}0.017\\0.016\\0.212\\0.225\end{bmatrix}$	$\begin{bmatrix}0.220\\0.234\\0.016\\0.017\end{bmatrix}$	$\begin{bmatrix}0.005\\0.006\\0.004\\0.007\end{bmatrix}$	$\begin{bmatrix}0.052\\0.051\\0.063\\0.064\end{bmatrix}$	$\begin{bmatrix}0.002\\0.003\\0.060\\0.059\end{bmatrix}$	$\begin{bmatrix}0.059\\0.059\\0.003\\0.003\end{bmatrix}$	$\begin{bmatrix}0.001\\0.005\\0.001\\0.014\end{bmatrix}$
$\begin{bmatrix}\widehat{ECM}(\hat{\phi})\\ \widehat{ECM}(\hat{\theta})\\ \widehat{ECM}(\hat{\Phi})\\ \widehat{ECM}(\hat{\Theta})\end{bmatrix}$	$\begin{bmatrix}0.269\\0.309\\0.257\\0.321\end{bmatrix}$	$\begin{bmatrix}0.033\\0.039\\0.264\\0.321\end{bmatrix}$	$\begin{bmatrix}0.240\\0.272\\0.033\\0.058\end{bmatrix}$	$\begin{bmatrix}0.009\\0.013\\0.012\\0.023\end{bmatrix}$	$\begin{bmatrix}0.197\\0.209\\0.204\\0.209\end{bmatrix}$	$\begin{bmatrix}0.017\\0.017\\0.212\\0.225\end{bmatrix}$	$\begin{bmatrix}0.220\\0.234\\0.017\\0.018\end{bmatrix}$	$\begin{bmatrix}0.005\\0.006\\0.004\\0.007\end{bmatrix}$	$\begin{bmatrix}0.052\\0.051\\0.063\\0.064\end{bmatrix}$	$\begin{bmatrix}0.002\\0.003\\0.060\\0.059\end{bmatrix}$	$\begin{bmatrix}0.059\\0.059\\0.003\\0.003\end{bmatrix}$	$\begin{bmatrix}0.001\\0.005\\0.001\\0.014\end{bmatrix}$
p-valor	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000	0.000

Tabla 3.4: Resultados de la estimación SARIMA(1,0,1)(1,0,1)$_4$, donde ECM denota el error cuadrático medio, y el p-valor corresponde al test de normalidad del vector $(\hat{\phi}, \hat{\theta}, \hat{\Phi}, \hat{\Theta})'$.

3.2. Predicción

Con el fin comprobar la bondad de las predicciones de los diferentes modelos expuestos en el capítulo anterior, se realizó un estudio de simulación, el cual consistió en simular series artificialmente para medir la proximidad de las predicciones a los valores reales de la serie simulada.

En cada simulación se generaron artificialmente B series de tiempo de tamaño $T + h$, se realizó la estimación de sus parámetros para cada una de ellas, y se realizaron las predicciones para los horizontes $1, \ldots, h$, con origen en T. Entonces, se dispondrán de B predicciones para cada horizonte temporal, con las cuales de podrán calcular una serie de métricas para evaluar la bondad de las predicciones. Es decir, se obtienen los siguientes valores simulados:

$$\left\{x_1^{(i)}, \ldots, x_T^{(i)}, x_{T+1}^{(i)}, ..., x_{T+h}^{(i)}\right\}_{i=1}^{B}$$

Es importante tomar un tamaño de muestra T suficientemente grande para que la estimación de los parámetros sea lo más precisa posible, ya que a diferencia de la sección anterior, lo que se pretende ahora es medir la calidad de las predicciones.

3.2.1. Predictores usados

A pesar de que el predictor óptimo es el presentado en el capítulo anterior ($P_1(X_{T+j}) := \hat{X}_T(j),\ \forall 1 \leq j \leq h$), se han definido una serie de predictores naif para comparar la calidad de las predicciones obtenidas con el predictor óptimo. Estos predictores son los siguientes:

- $P_2(X_{T+j}) := \hat{\mu},\ \forall 1 \leq j \leq h$, donde μ es la media del proceso. En este caso se generarán procesos donde $\mu = 0$. Este predictor solo se usará para los procesos estacionarios (AR, MA y ARMA). De hecho, este es el predictor óptimo para una serie de tiempo generada por un proceso de ruido blanco, al que se le suma la constante μ.
- $P_3(X_{T+j}) := x_T,\ \forall 1 \leq j \leq h$. Es decir, la predicción es el valor anterior de la serie. Este predictor solo se usará para los procesos estacionarios (AR, MA y ARMA).
- P_4 que consiste en predecir valores futuros usando una regresión lineal de los últimos 25 instante temporales. Solo se usará para el proceso ARIMA.
- Para los procesos estacionales (SARIMA) de período s, se define $P_5(X_{T+j}) := P_5(X_{T+j-s})$ $\forall j > s$, y $P_5(X_{T+j}) := x_{T+j-s}\ \ \forall 1 \leq j \leq s$. Es decir, P_5 consiste en predecir el valor del proceso en el instante $T + j$ como el valor del proceso en el instante $T + j - s$.

Para medir la adecuación de las predicciones realizadas por el predictor P_j, $j \in \{1, 2, 3, 4, 5\}$, se utilizará el error absoluto medio (MAE, de *Mean Absolute Error* en inglés), definido como:

$$\mathrm{MAE}_j(h) = \frac{1}{B}\sum_{i=1}^{B} \mathrm{AE}_j^i(h),$$

donde

$$\mathrm{AE}_j^i(h) = |x_{T+h}^{(i)} - P_j(x_{T+h}^{(i)})|.$$

Además, para comparar el error entre las diferentes métricas, se calculará el error relativo de la métrica j' con respecto a la métrica j en el retardo h, tal y como sigue:

$$\mathrm{RMAE}_j^{j'}(h) = \frac{\mathrm{MAE}_{j'}(h)}{\mathrm{MAE}_j(h)}.$$

En la Tabla 3.5 se muestran los resultados de las simulaciones para varios procesos distintos, cuyos datos han sido graficados en la Figura 3.1. En la Tabla 3.6 se muestra la mejora de cada métrica con respecto a una métrica de referencia, que en el caso de los procesos estacionarios es la 2; para los procesos ARIMA es la 4; y para los procesos SARIMA es la 5.

Proceso	Parámetros	Métricas \ h	1	2	3	4	5	6	7	8	9	10
AR(1)	$\left[\phi_1 = 0.1\right]$	MAE_1	0.823	0.800	0.807	0.798	0.781	0.798	0.808	0.811	0.810	0.795
		MAE_2	0.820	0.800	0.806	0.798	0.781	0.798	0.808	0.811	0.810	0.795
		MAE_3	1.071	1.183	1.177	1.184	1.158	1.140	1.127	1.106	1.152	1.178
	$\left[\phi_1 = 0.5\right]$	MAE_1	0.794	0.849	0.889	0.906	0.852	0.875	0.897	0.877	0.953	0.952
		MAE_2	0.914	0.888	0.892	0.910	0.855	0.876	0.898	0.877	0.953	0.952
		MAE_3	0.914	1.064	1.216	1.260	1.198	1.253	1.285	1.270	1.333	1.352
	$\left[\phi_1 = 0.9\right]$	MAE_1	0.757	1.097	1.264	1.401	1.551	1.617	1.715	1.717	1.750	1.886
		MAE_2	1.824	1.867	1.865	1.884	1.926	1.911	1.951	1.894	1.882	1.987
		MAE_3	0.769	1.146	1.322	1.485	1.649	1.774	1.911	2.004	2.055	2.178
AR(5)	$\begin{bmatrix} \phi_1 = 2.5 \\ \phi_2 = -2.45 \\ \phi_3 = 1.175 \\ \phi_4 = -0.2754 \\ \phi_5 = 0.0252 \end{bmatrix}$	MAE_1	0.850	2.278	3.934	5.484	6.691	7.541	8.161	8.618	8.995	9.226
		MAE_2	9.128	9.189	9.319	9.471	9.514	9.405	9.196	9.045	9.123	9.195
		MAE_3	2.222	4.299	6.100	7.614	8.749	9.686	10.450	11.052	11.653	12.173
MA(1)	$\left[\theta_1 = 0.1\right]$	MAE_1	0.828	0.811	0.790	0.822	0.824	0.818	0.825	0.801	0.787	0.798
		MAE_2	0.836	0.811	0.790	0.822	0.824	0.818	0.825	0.801	0.787	0.798
		MAE_3	1.048	1.093	1.071	1.075	1.125	1.101	1.141	1.142	1.133	1.108
	$\left[\theta_1 = 0.5\right]$	MAE_1	0.781	0.864	0.846	0.908	0.878	0.899	0.878	0.872	0.933	0.804
		MAE_2	0.896	0.864	0.846	0.908	0.878	0.899	0.878	0.872	0.933	0.804
		MAE_3	0.939	1.206	1.255	1.326	1.279	1.250	1.256	1.249	1.263	1.220
	$\left[\theta_1 = 0.9\right]$	MAE_1	0.834	1.065	1.109	1.094	1.124	1.066	1.100	1.123	1.089	1.141
		MAE_2	1.070	1.065	1.109	1.094	1.124	1.066	1.100	1.123	1.089	1.141
		MAE_3	1.100	1.488	1.552	1.507	1.536	1.561	1.558	1.600	1.540	1.601
MA(5)	$\begin{bmatrix} \theta_1 = -2.5 \\ \theta_2 = 2.45 \\ \theta_3 = -1.175 \\ \theta_4 = 0.2754 \\ \theta_5 = -0.0252 \end{bmatrix}$	MAE_1	0.796	2.118	2.878	3.092	3.108	3.047	3.056	3.001	3.000	2.960
		MAE_2	2.981	2.962	2.991	3.102	3.111	3.047	3.056	3.001	3.000	2.960
		MAE_3	5.804	3.308	4.675	4.300	4.538	4.512	4.213	4.462	4.303	4.331
ARIMA(2,1,2)	$\begin{bmatrix} \phi_1 = 0.6 \\ \phi_2 = 0.3 \\ \theta_1 = 0.6 \\ \theta_2 = -0.3 \end{bmatrix}$	MAE_1	0.778	1.871	2.960	4.160	5.440	6.820	8.183	9.534	10.873	12.261
		MAE_4	8.593	10.136	11.746	13.436	15.055	16.556	18.093	19.668	21.292	22.994
SARIMA $(1,0,1)(1,0,1)_{12}$	$\begin{bmatrix} \phi_1 = 0.7 \\ \theta_1 = 0.7 \\ \Phi_1 = 0.7 \\ \Theta_1 = 0.7 \end{bmatrix}$	MAE_1	0.807	1.418	1.581	1.600	1.624	1.757	1.762	1.740	1.796	1.838
		MAE_5	2.223	2.221	2.187	2.021	2.041	2.124	2.128	2.171	2.200	2.159

Tabla 3.5: Resultados del estudio de simulación de la estimación de procesos AR, MA, ARMA, ARIMA y SARIMA. Se muestran las métricas de error absolutas (MAE) a diferentes horizontes de predicción (h).

Proceso	Parámetros	Métricas \ h	1	2	3	4	5	6	7	8	9	10
AR(1)	$\left[\phi_1 = 0.1\right]$	RMAE_2^1	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
		RMAE_2^3	0.77	0.68	0.69	0.67	0.67	0.70	0.72	0.73	0.70	0.67
	$\left[\phi_1 = 0.5\right]$	RMAE_2^1	1.15	1.05	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
		RMAE_2^3	1.00	0.83	0.73	0.72	0.71	0.70	0.70	0.69	0.72	0.70
	$\left[\phi_1 = 0.9\right]$	RMAE_2^1	2.41	1.70	1.47	1.34	1.24	1.18	1.14	1.10	1.08	1.05
		RMAE_2^3	2.37	1.63	1.41	1.27	1.17	1.08	1.02	0.95	0.92	0.91
AR(5)	$\begin{bmatrix} \phi_1 = 2.5 \\ \phi_2 = -2.45 \\ \phi_3 = 1.175 \\ \phi_4 = -0.2754 \\ \phi_5 = 0.0252 \end{bmatrix}$	RMAE_2^1	10.73	4.03	2.37	1.73	1.42	1.25	1.13	1.05	1.01	1.00
		RMAE_2^3	4.11	2.14	1.53	1.24	1.09	0.97	0.88	0.82	0.78	0.76
MA(1)	$\left[\theta_1 = 0.1\right]$	RMAE_2^1	1.01	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
		RMAE_2^3	0.80	0.74	0.74	0.76	0.73	0.74	0.72	0.70	0.69	0.72
	$\left[\theta_1 = 0.5\right]$	RMAE_2^1	1.15	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
		RMAE_2^3	0.95	0.72	0.67	0.68	0.69	0.72	0.70	0.70	0.74	0.66
	$\left[\theta_1 = 0.9\right]$	RMAE_2^1	1.28	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
		RMAE_2^3	0.97	0.72	0.71	0.73	0.73	0.68	0.71	0.70	0.71	0.71
MA(5)	$\begin{bmatrix} \theta_1 = -2.5 \\ \theta_2 = 2.45 \\ \theta_3 = -1.175 \\ \theta_4 = 0.2754 \\ \theta_5 = -0.0252 \end{bmatrix}$	RMAE_2^1	3.74	1.40	1.04	1.00	1.00	1.00	1.00	1.00	1.00	1.00
		RMAE_2^3	0.51	0.90	0.64	0.72	0.69	0.68	0.73	0.67	0.70	0.68
ARIMA(2,1,2)	$\begin{bmatrix} \phi_1 = 0.6 \\ \phi_2 = 0.3 \\ \theta_1 = 0.6 \\ \theta_2 = -0.3 \end{bmatrix}$	RMAE_4^1	11.04	5.42	3.97	3.23	2.77	2.43	2.21	2.06	1.96	1.88
SARIMA $(1,0,1)(1,0,1)_{12}$	$\begin{bmatrix} \phi_1 = 0.7 \\ \theta_1 = 0.7 \\ \Phi_1 = 0.7 \\ \Theta_1 = 0.7 \end{bmatrix}$	RMAE_5^1	2.75	1.57	1.38	1.26	1.26	1.21	1.21	1.25	1.22	1.17

Tabla 3.6: Resultados del estudio de simulación de la estimación de procesos AR, MA, ARMA, ARIMA y SARIMA. Se muestran las métricas de error relativas (RMAE) a diferentes horizontes de predicción (h).

3.2.2. Discusión de los resultados

Procesos AR(1)

- A la vista de la Tabla 3.6, cuanto mayor es el valor absoluto de ϕ, mejores son las predicciones del predictor natural (P_1) en comparación con el predictor 2 (la media del proceso). Esto es esperable, debido a que al aumentar el valor absoluto de ϕ, hay mayor correlación temporal entre los valores de la serie, pareciéndose cada vez menos el proceso al ruido blanco.
- Para $\phi = 0.1$, el proceso es prácticamente ruido blanco, obteniendo el predictor 1 y 2 resultados muy similares (de hecho el error absoluto relativo es muy próximo a 1, tal y como muestra la Tabla 3.6). Además, también se observa que el predictor 3 es peor que los dos anteriores, lo cual parece lógico, ya que el proceso está más cerca de ser ruido blanco que de un proceso autorregresivo, por lo que predecir suponiendo correlación lineal completa va a dar malos resultados.
- En cambio, para $\phi = 0.9$, al haber bastante correlación temporal, el predictor 1 obtiene unos resultados notablemente mejores que el predictor 2 ($\mathrm{RAE}_2^1(1) = 2.41$), ya que mientras el primero es capaz de aprovechar dicha correlación, el segundo no. Además, para este valor de ϕ, el predictor 3 es muy similar al predictor 2, de ahí los resultados similares obtenidos.
- A medida que se aumenta el horizonte de predicción, los errores aumentan, como es lógico, ya que la incertidumbre aumenta con el horizonte de predicción. Sin embargo, para $\phi = 0.9$, el predictor 1 sigue siendo mejor que el predictor 2 incluso para horizontes de predicción grandes. No obstante, esta diferencia se va reduciendo a medida que aumenta el horizonte de predicción, y para $h \geq 6$, ambos predictores son prácticamente iguales.

Proceso AR(5)

La bondad de predicción del predictor 1 con respecto a los otros dos es mucho más acentuada que en el caso anterior, ya que en este proceso la estructura de correlación temporal es más compleja. De hecho, en este caso, para $h = 1$, el predictor 1 tiene un error absoluto medio 10 veces menor que el predictor 2, tal y como se observa en la Tabla 3.6. No obstante, se observa que a medida que se aumenta el horizonte de predicción, esta diferencia va disminuyendo.

Procesos MA(1)

Una diferencia importante entre los procesos AR y MA es que en el caso de los procesos MA, el predictor 1 (el natural) es exactamente igual al predictor 2 (la media del proceso) cuando $h > q$,

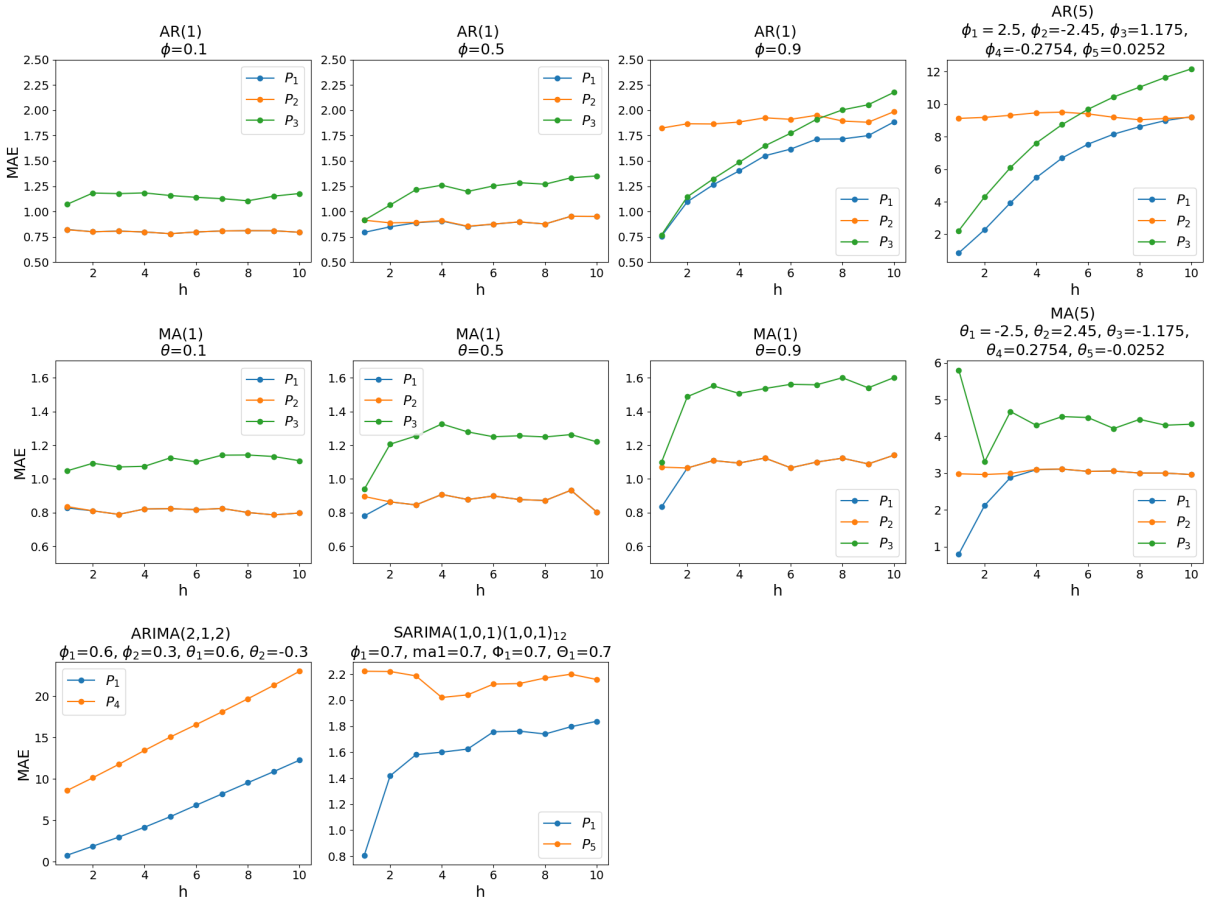

Figura 3.1: Gráficos de los datos de la Tabla 3.5. Cada gráfico muestra el error de los diferentes predictores para un proceso concreto.

donde q es el orden del proceso MA. Esto se puede comprobar en la Tabla 3.5, aunque ya se había comprobado de forma teórica en el capítulo anterior.

Por otra parte, se puede concluir que el predictor 3 (valor anterior) predice peor que el predictor 2, ya que el error absoluto medio relativo es menor que 1 en todos los casos.

Procesos MA(5)

Se obtiene que para $h = 1$ el predictor 1 es 3.74 veces mejor que el predictor 2, y a medida que se aumenta el horizonte de predicción, esta diferencia va disminuyendo, siendo iguales para $h \geq 6$. Ya se había comentado anteriormente que al realizar la predicción para $h > q$, la predicción asociada a la parte de medias móviles es igual a la media del proceso.

Proceso ARIMA(2,1,2)

El predictor natural obtiene resultados notablemente mejores que el predictor naif. De hecho $\mathrm{RAE}_4^1(1) = 11.04$, lo cual indica que el predictor 1 es más de 11 veces mejor que el naif.

Por otra parte, los error absolutos medios de predicción aumentan al aumentar el horizonte de predicción, como es lógico.

Proceso SARIMA(1,0,1)(1,0,1)$_{12}$

Comparando los errores absoluto medios, para $h = 1$ el predictor natural es 2.75 veces mejor que el predictor naif. No obstante, esta diferencia se va reduciendo a medida que se aumenta el horizonte de predicción.

Conclusión sobre los resultados de predicción

Como era de esperar, el predictor natural (el óptimo) es el que mejores resultados ha obtenido, siendo esta diferencia mayor cuánta mayor es la correlación temporal entre los valores de la serie, y cuanto menor es el horizonte de predicción. En cambio, para horizontes temporales grandes es complicado realizar una predicción. De hecho, la predicción óptima acaba siendo una predicción naif, como la media del proceso en el caso de los procesos estacionarios.

Capítulo 4

Ilustración con datos reales

En este capítulo se analizarán un par de series de tiempo reales, con el objetivo de poner en práctica los conceptos y técnicas expuestos en el Capítulo 2. La primera serie de tiempo a analizar corresponde a las cotizaciones del índice bursatil IBEX 35, mientras que la segunda serie al consumo mensual de electricidad en Estados Unidos. En ambos casos, se realizará el análisis en las 3 etapas expuestas en la Sección 2.8.

Al igual que en el Capítulo anterior, se usaron las funciones `Arima` y `forecast` de la librería `forecast` de R para realizar el análisis de las series de tiempo. De ese mismo paquete también se usó la función `auto.arima` para buscar el mejor modelo en base al AICc de entre todos los modelos cuyo orden sea menor que un umbral dado. También se usaron `checkresiduals` del mismo paquete, o `shapiro.test` y `t.test` del paquete `stats` para realizar las pruebas de normalidad y de media nula, respectivamente.

4.1. Análisis de la serie de tiempo del IBEX 35

Los datos corresponden a las cotizaciones diarias del índice bursátil IBEX 35, obtenidos de [7] y abarcan desde el 10 de junio de 2024 hasta el 9 de junio de 2025, con una frecuencia diaria. No obstante, esta frecuencia es irregular, ya que no se disponen de datos para los fines de semana y festivos. Además, se reservarán los 10 últimos valores de la serie para realizar predicciones.

4.1.1. Etapa 1: Identificación de modelos compatibles con la serie

En la Figura 4.1 se muestra el gráfico secuencial de la serie. La primera consideración a tener en cuenta es que al ser una serie financiera, es recomendable trabajar con el logaritmo de las

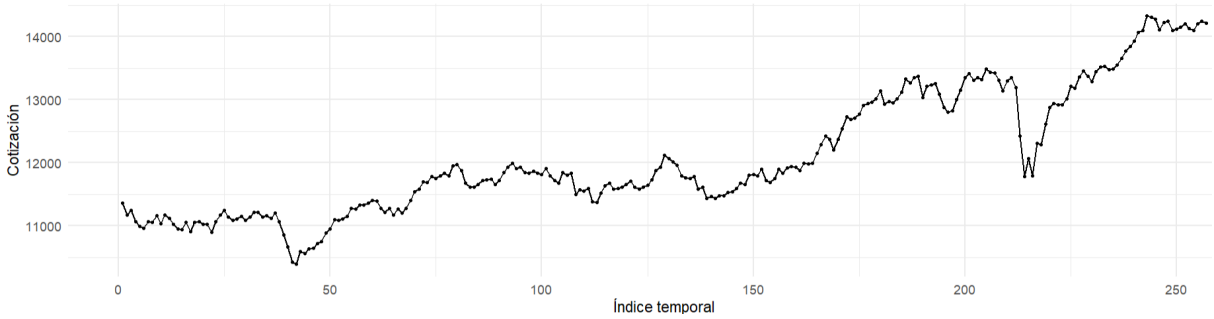

Figura 4.1: Gráfico secuencial de la serie de tiempo del IBEX 35.

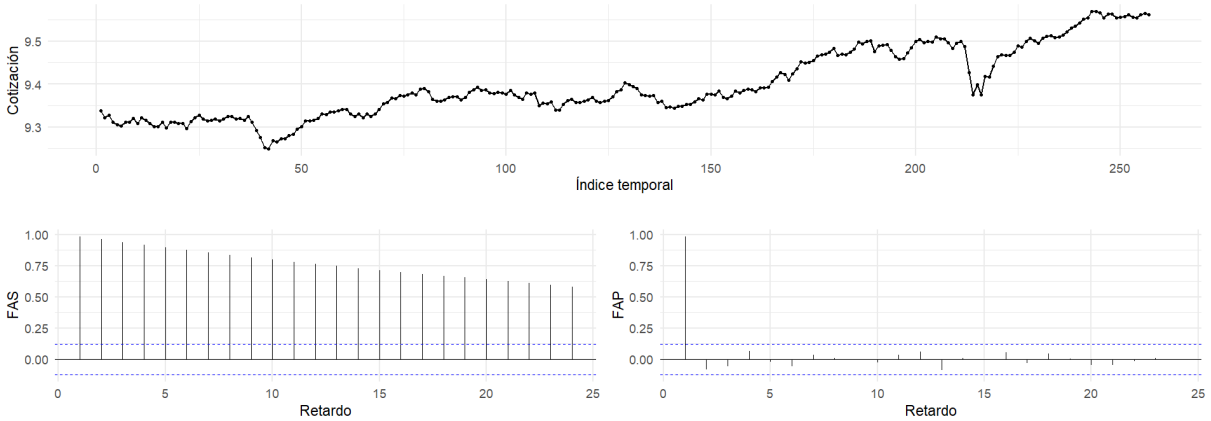

Figura 4.2: Gráfico secuencial del logaritmo de la serie de tiempo del IBEX 35 (arriba), gráfico de la fas muestral (abajo izquierda) y gráfico de la fap muestral (abajo derecha).

cotizaciones, ya que en este tipo de series las subidas y bajadas son proporcionales al valor de la serie. En la Figura 4.2 se muestra el gráfico secuencial de la log-serie, junto a la fas y fap muestral. En dicho gráfico secuencial se puede concluir que la serie transformada presenta tendencia clara. Además, el hecho de que los valores de la fas muestral decaigan lentamente y linealmente apoya esta conclusión. Para eliminar la tendencia, se aplica una diferencia regular. El resultado se muestra en la Figura 4.3, en la cual se aprecia que la tendencia ha desaparecido. Además, el resultado parece una serie estacionaria, por la que ya se está en condiciones de identificar algún modelo para la log-serie diferenciada.

Como en la estimación de la fas el menor retardo con un valor fuera de los límites azules es 2, se puede proponer un MA(2) como proceso de generador de la log-serie diferenciada. Por otra parte, en la estimación de la fap, el mayor retardo con un valor fuera de los límites azules es 2, por lo que también se puede proponer un AR(2) como proceso generador. Además, como en ambos casos dichos límites no son superados claramente, se propondrá un tercer modelo para la log-serie diferenciada: un ARMA$(0, 0)$, i.e., ruido blanco. En resumen, se proponen tres procesos

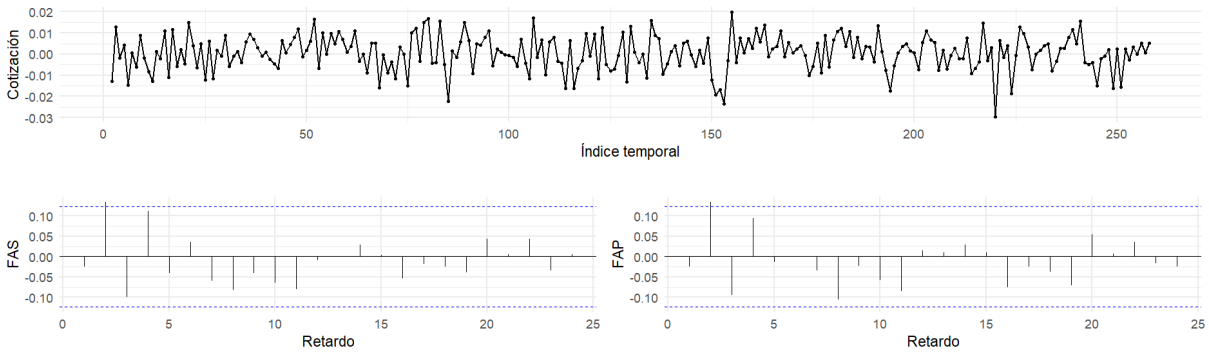

Figura 4.3: Gráfico secuencial de la serie transformada tras una diferencia regular, gráfico de la fas muestral (abajo izquierda) y gráfico de la fap muestral (abajo derecha).

generadores de la log-serie: un ARIMA$(2,1,0)$, un ARIMA$(0,1,2)$ y un ARIMA$(0,1,0)$.

4.1.2. Etapa 2: Estimación de los modelos y selección de un modelo

Se utiliza la función `auto.arima` de la librería `forecast` de R para estimar y seleccionar automáticamente el mejor modelo en base al AICc, de entre todos aquellos modelos cuyos órdenes sean menores que un umbral dado. Para el modelo ARIMA$(2,1,0)$, es AICc obtenido es -1730.601; para ARIMA$(0,1,2)$, -1729.652; y para ARIMA$(0,1,0)$, -1729.638. En cambio, de todos los modelos probados por la función `auto.arima` de R, el modelo ARIMA$(1,1,2)$ es el que obtuvo el menor AICc, -1732.799. Como el AICc de este último es menor que el resto en más de 2 unidades, se selecciona este modelo como el mejor.

Con respecto a la estimación del modelo ARIMA$(1,1,2)$, se ha obtenido que $\hat{\phi}_1 = -0.7389$, $\hat{\sigma}(\hat{\phi}_1) = 0.1451$; $\hat{\theta}_1 = 0.7467$, $\hat{\sigma}(\hat{\theta}_1) = 0.1516$; y $\hat{\theta}_2 = 0.1392$, $\hat{\sigma}(\hat{\theta}_2) = 0.0667$. Teniendo en cuenta que estos estimadores son asintóticamente normales, se puede aplicar el test de Wald, y se concluye que para un nivel de significación del 95 %, todos los coeficientes son significativos porque $(-0.7389 \pm 0.1451 z_{0.05/2})$, $(0.7467 \pm 0.1516 z_{0.05/2})$ y $(0.1392 \pm 0.0667 z_{0.05/2})$ no contienen el cero, siendo $z_{0.05/2}$ el cuantil 2.5 % de una distribución normal estándar.

4.1.3. Etapa 3: Diagnosis del modelo seleccionado

A continuación se comprobará si el modelo seleccionado es válido. Para ello, se analizarán los residuos del modelo, los cuales se graficaron en la Figura 4.4, donde se observa que:

- La media de los residuos parece ser nula. Para comprobarlo, se realizó la prueba t de Student, y el p-valor obtenido fue de 0.3273, por lo que para cualquier nivel de significación

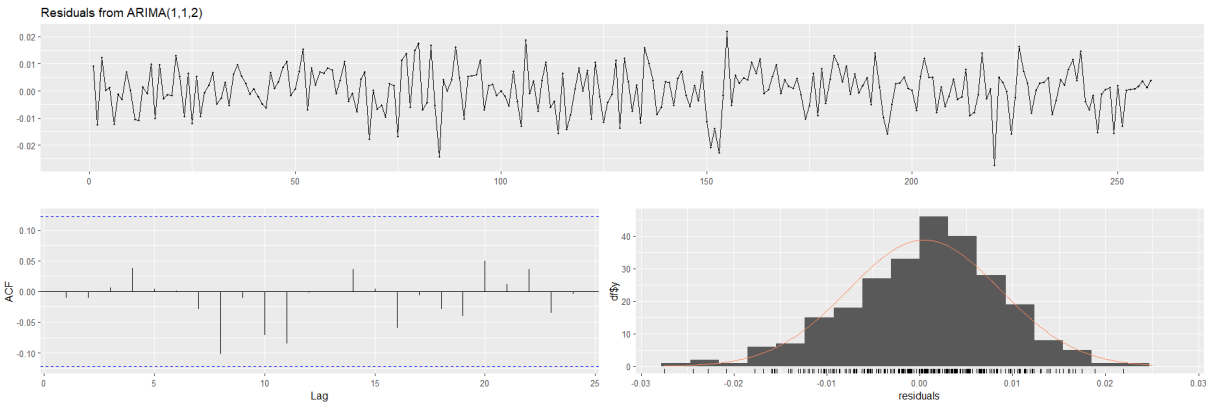

Figura 4.4: Gráfico de los residuos del modelo ARIMA(1,1,2) seleccionado.

de habitual se puede aceptar que los residuos tienen media nula.

- La varianza de los residuos parece constante a lo largo del tiempo.
- La autocorrelación de los residuos parece ser nula, ya que todas las estimaciones están dentro de las líneas azules. Otra forma de comprobarlo es realizando la prueba de Ljung-Box, cuyo p-valor obtenido fue de 0.6723, por lo que para cualquier nivel de significación de habitual se puede aceptar que los residuos están incorrelados.

Por lo tanto, se puede concluir que el modelo ARIMA$(1, 1, 2)$ es un modelo válido como generador de la log-serie del IBEX 35.

La Figura 4.4 permite la comparación visual entre el histograma de los residuos y la función de densidad de una normal estándar, a partir del cual es posible dar una conclusión clara. Realizando un contraste de Shapiro-Wilk, se obtiene un p-valor de 0.07629. No obstante, el test de Jarque-Bera da un p-valor de 0.02198, por lo que se para un nivel de significación del 5 %, se rechaza que los residuos tengan la simetría o la kurtosis de una distribución normal estándar, por lo que se rechaza la normalidad de los residuos.

4.1.4. Predicciones

En la Figura 4.5 se muestran las predicciones del modelo ARIMA(1,1,2) para los 10 días hábiles siguientes al último valor de la serie, junto a los valores reales de la serie. Además, se muestran las bandas de confianza al 80 % y al 95 % de las predicciones, calculadas mediante *bootstrap* (debido a que las innovaciones no son gaussianas). El valor real de la serie se encuentra dentro de estas bandas.

Con respecto a la calidad de las predicciones, el análisis visual del gráfico sugiere que el modelo ARIMA(1,1,2) no logra unas predicciones cercanas a los valores reales, ni siquiera en el horizonte

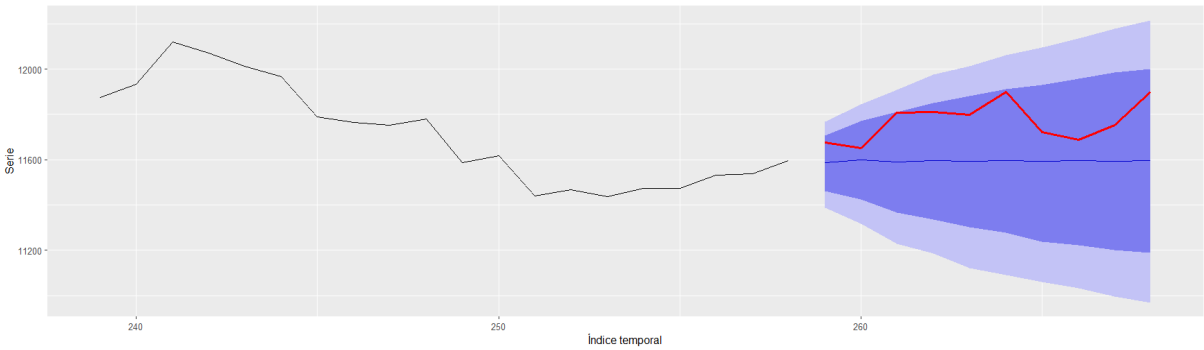

Figura 4.5: Predicciones del modelo ARIMA(1,1,2) para los 10 días hábiles siguientes (azul) frente a los valores reales (rojo).

de predicción más inmediato ($h = 1$).

4.2. Análisis de la serie de tiempo de consumo de electricidad en EEUU

El segundo conjunto de datos a analizar se corresponde al consumo mensual de electricidad en Estados Unidos, obtenido de [10], y abarca desde enero de 1973 hasta diciembre de 2019, con una frecuencia mensual. Se reservarán los últimos 12 meses para realizar predicciones, por lo que se trabajará con los datos desde enero de 1973 hasta diciembre de 2018. Las unidades del consumo son cuadrillones de BTU (*British Thermal Unit*, unidad de energía térmica).

4.2.1. Etapa 1: Identificación de modelos compatibles con la serie

En la Figura 4.6 se muestra el gráfico secuencial de la serie. Parece que la serie es homocedástica, de hecho, estimando λ tal y como se propuso en el Capítulo 2.8.1, se obtuvo un valor próximo

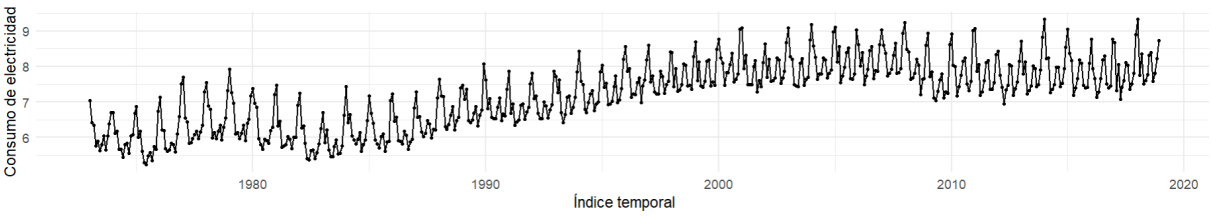

Figura 4.6: Gráfico secuencial de la serie de consumo de electricidad en EEUU (arriba), gráfico de la fas muestral (abajo izquierda) y gráfico de la fap muestral (abajo derecha).

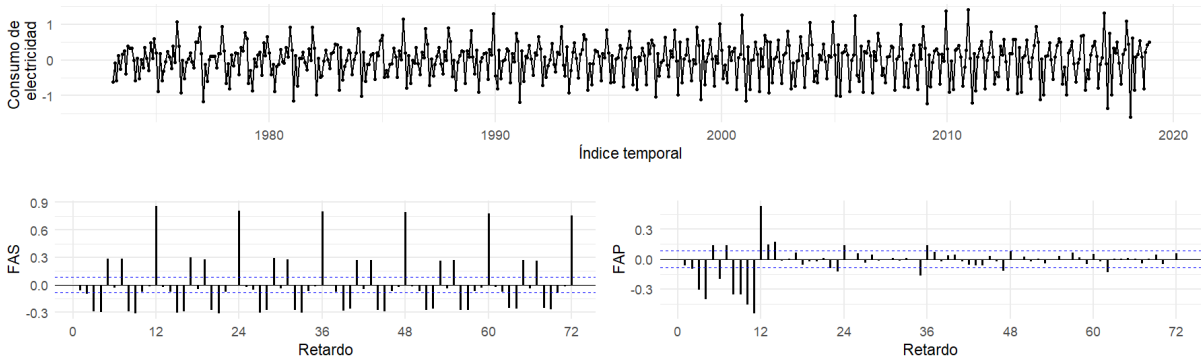

Figura 4.7: Gráfico de la serie de consumo de electricidad en EEUU tras una diferencia regular (arriba), gráfico de la fas muestral (abajo izquierda) y gráfico de la fap muestral (abajo derecha).

a 1. Otro hecho que evidencia la homocedasticidad, es que agrupando los datos en grupos de 12 observaciones, el coeficiente de correlación lineal entre la media y las desviaciones típicas de los grupos es de próximo a 0.

No obstante, la serie presenta una tendencia clara, como se puede observar en el gráfico secuencial. Además, el hecho de que los valores de la fas muestral decaigan lentamente y linealmente apoya esta conclusión. Para eliminar la tendencia, se aplica una diferenciación regular. El resultado se muestra en la Figura 4.7, en la cual se aprecia que la tendencia ha desaparecido. A partir de dicha Figura se puede concluir también que la serie es estacional con período 12, ya que los coeficientes de la fas muestral que son múltiplos de 12 son positivos, grandes y decaen lentamente. Por lo tanto, se aplicará una diferencia estacional de período 12 para eliminar la estacionalidad.

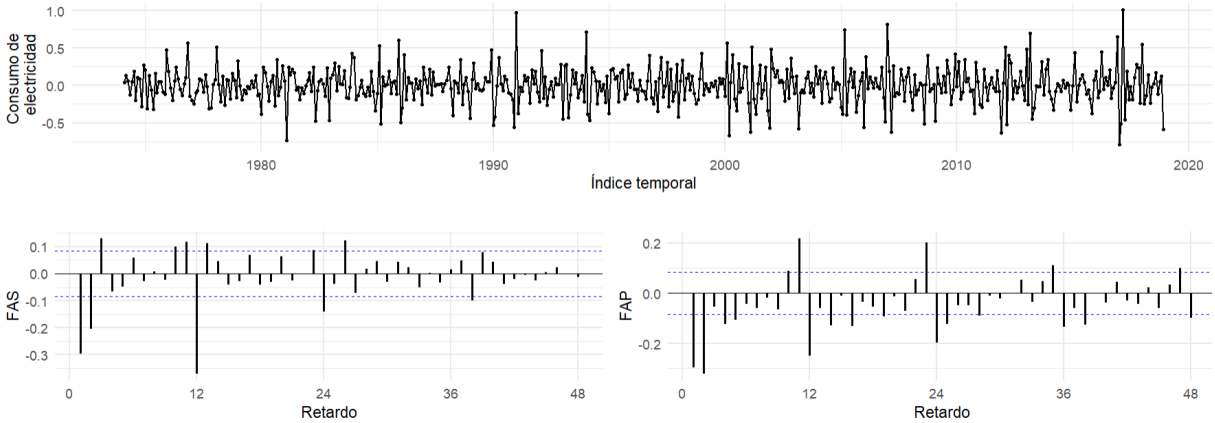

Figura 4.8: Gráfico de la serie de consumo de electricidad en EEUU tras una diferencia regular y una diferencia estacional (arriba), gráfico de la fas muestral (abajo izquierda) y gráfico de la fap muestral (abajo derecha).

A partir de la Figura 4.8 se puede concluir que tras aplicar la diferencia estacional, la serie obtenida parece estacionaria. Por lo tanto, ya se pueden proponer modelos para la serie original. Para ello se tendrán en cuenta los gráficos de la fas y fap muestral de la serie transformada, mostrados también en la Figura 4.8. Se proponen los siguientes modelos, siguiendo los criterios de identificación de modelos del Capítulo 2: SARIMA(0,1,3)$(0,1,2)_{12}$, SARIMA(0,1,3)$(4,1,0)_{12}$, SARIMA(5,1,0)$(0,1,2)_{12}$ y SARIMA(5,1,0)$(4,1,0)_{12}$.

4.2.2. Etapa 2: Estimación de los modelos candidatos y selección de un modelo

Se utiliza la función `auto.arima` de la librería `forecast` de R para estimar y seleccionar automáticamente el mejor modelo en base al AICc, entre todos aquellos modelos cuyos órdenes sean menores que un umbral dado. En la Tabla 4.1 se muestra el AICc obtenido para cada uno de los modelos candidatos, siendo el quinto modelo el propuesto por esta función.

Modelo	AICc
SARIMA(0,1,3)$(0,1,2)_{12}$	-320.5516
SARIMA(0,1,3)$(4,1,0)_{12}$	-308.1312
SARIMA(5,1,0)$(0,1,2)_{12}$	-316.2342
SARIMA(5,1,0)$(4,1,0)_{12}$	-304.1946
SARIMA(0,1,4)$(2,1,2)_{12}$	-332.3346

Tabla 4.1: AICc de los modelos candidatos para la serie del consumo de electricidad mensual en EEUU.

Como el AICc del modelo SARIMA(0,1,4)$(2,1,2)_{12}$ dista en más de 2 unidades del AICc de los otros modelos candidatos, se selecciona este modelo como el mejor. Se analizó la significación de los coeficientes del modelo del mismo modo que para la serie del IBEX 35, y se obtuvo que el parámetro θ_3 no era significativo. Por lo tanto, se volvió a ajustó el modelo SARIMA(0,1,4)$(2,1,2)_{12}$ eliminando dicho parámetro. El modelo resultante tenía todos los coeficientes significativos, y obtuvo un AICc de -333.8911.

4.2.3. Etapa 3: Diagnosis del modelo seleccionado

A continuación se comprobará si el modelo seleccionado es válido. Para ello, se analizarán los residuos del modelo, los cuales se graficaron en la Figura 4.9. En él se observa que:

- La media de los residuos parece ser nula. Para comprobarlo, se realizó la prueba t de

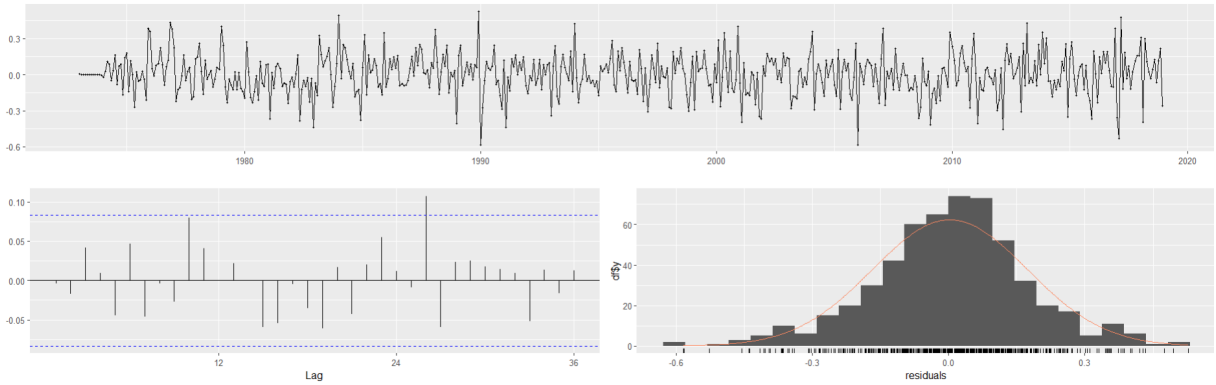

Figura 4.9: Gráfico de los residuos del modelo SARIMA seleccionado.

Student, y el p-valor obtenido fue de 0.6796, por lo que para cualquier nivel de significación de habitual se puede aceptar que los residuos tienen media nula.

- La varianza de los residuos parece constante a lo largo del tiempo.

- Aunque en el gráfico de la fas muestral de los errores tiene algún valor ligeramente significativo para un retardo, el p-valor obtenido en la prueba de Ljung-Box es 0.2279, por lo que, para un nivel de significación del 5 % no hay evidencias para rechazar la incorrelación de los residuos.

Por lo tanto, se puede concluir que el modelo SARIMA$(0,1,4)(2,1,2)_{12}$, con θ_3 fijado a 0 es un modelo válido como generador de la serie transformada del número de accidentes de tráfico en España.

Con respecto a los tests de normalidad, el test de Shapiro-Wilk da un p-valor de 0.002035, por lo que para un nivel de significación del 5 % se rechaza que los residuos tengan una distribución normal. Además, el test de Jarque-Bera también rechaza la normalidad de los residuos, ya que el p-valor obtenido es 0.001569. Por lo tanto, se concluye que los residuos no son normales.

4.2.4. Predicciones

En la Figura 4.10 se muestran las predicciones del modelo seleccionado para los 12 meses siguientes a diciembre de 2018, junto a los valores reales de la serie. Además, se muestran las bandas de confianza al 80 % y al 95 % de las predicciones, calculadas mediante *bootstrap* (debido a que las innovaciones no son gaussianas).

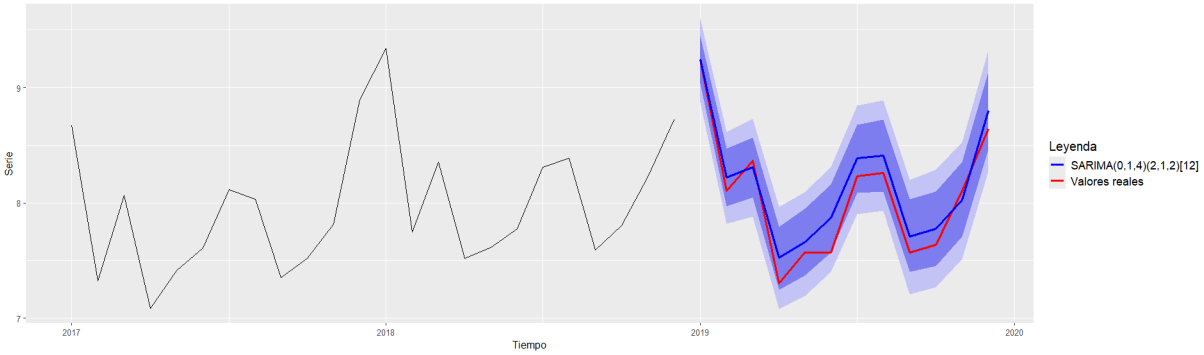

Figura 4.10: Predicción de los consumos mensuales de electricidad en EEUU para los 12 meses siguientes a diciembre de 2018. En azul, las predicciones del modelo SARIMA(0,1,4)(2,1,2)$_{12}$, con θ_3 fijado a 0; en rojo, los valores reales.

Anexo I

Resultados de teoría de la probabilidad usados

A continuación se muestran algunos resultados de Teoría de la Probabilidad, tomados de [11], que fueron resultados para demostrar algunos resultados del Capítulo 2.

Proposición I.1. La convergencia en media r-ésima implica la convergencia en probabilidad.

Teorema I.2 (Teorema de convergencia monótona)**.** Sea $\{X_n\}_{n\geq 1}$ una sucesión de variables aleatorias no negativas y monótonas crecientes tales que convergen a la variable aleatoria X, i.e. $X_n \uparrow X$ de forma casi segura. Entonces

$$\lim_{n\to\infty} \mathbb{E}[X_n] = \mathbb{E}[X].$$

Corolario I.3. Sea $\{X_n\}_{n\geq 1}$ una sucesión de variables aleatorias no negativas, entonces

$$\mathbb{E}\left[\sum_{n=1}^{\infty} X_n\right] = \sum_{n=1}^{\infty} \mathbb{E}[X_n].$$

Observación I.4. En el resultado anterior, la serie no tiene por qué ser convergente.

Proposición I.5 (Propiedades de la convergencia en media cuadrática)**.** Sean X_n y Y_n dos sucesiones de variables aleatorias tales que $X_n \xrightarrow{m.s.} X$ y $Y_n \xrightarrow{m.s.} Y$, donde X e Y son también variables aleatorias. Entonces, cuando $n \to \infty$,

(i) $\mathbb{E}(X_n Y_n) \xrightarrow{n\to\infty} \mathbb{E}(XY)$

(ii) $\mathbb{E}|X_n^2| \xrightarrow{n\to\infty} \mathbb{E}|X^2|$

(iii) $\mathbb{E}(X_n) \xrightarrow{n\to\infty} \mathbb{E}(X)$.

Bibliografía

[1] Box, G.E.P. y Jenkins, G.M., *Time Series Analysis: Forecasting and Control*, Holden-Day Series in Time Series Analysis and Digital Processing, Holden-Day, 1976.

[2] Brockwell, P.J. y Davis, R.A., *Introduction to Time Series and Forecasting*, 3ª ed., Springer Texts in Statistics, Springer International Publishing, 2016.

[3] P. J. Brockwell and R. A. Davis, *Time Series: Theory and Methods*, Springer, 1991. ISBN: 978-1-4419-0319-8.

[4] Quenouille, M. H. (1949). Approximate tests of correlation in time-series. *Journal of the Royal Statistical Society. Series B (Methodological)*, 11, 68–84.

[5] Peña, D., *Análisis de series temporales*. Manuales. Alianza Editorial, 2010.

[6] David A. Dickey y Wayne A. Fuller. *Distribution of the estimators for autoregressive time series with a unit root.* Journal of the American Statistical Association, 74(366):427–431, 1979.

[7] Investing.com, *Datos históricos del índice Ibex 35*. Disponible en: `https://es.investing.com/indices/spain-35-historical-data`. Consultado el 9 de junio de 2025.

[8] Instituto Canario de Estadística (ISTAC), *Tráfico aéreo comercial de pasajeros, aviones y mercancías por aeropuertos, por islas de Canarias y periodos*, 2024. Disponible en: `https://datos.gob.es/es/catalogo/a05003423-trafico-aereo-comercial-de-pasajeros-aviones-y-mercancias-por-aeropuertos-por-` Consultado el 12 de junio de 2025.

[9] Investing.com, *S&P 500 Historical Data (SPX)*, disponible en `https://es.investing.com/indices/us-spx-500-historical-data`. Consultado el 25 de junio de 2025.

[10] U.S. Energy Information Administration, *Monthly Energy Review*, Disponible en: `https://www.eia.gov/totalenergy/data/monthly/`. Consultado el 29 de junio de 2025.

[11] Billingsley, P. (1995). *Probability and Measure*, 3ª Edición. John Wiley & Sons, Nueva York.